

GRADO EN CIENCIA DE DATOS



VNIVERSITAT
ID VALÈNCIA

TRABAJO FIN DE GRADO

DEEP LEARNING APLICADO A LA CLASIFICACIÓN Y SEGMENTACIÓN DE IMÁGENES DE TUMORES CEREBRALES

AUTOR:

JORGE ALBALAT LUENGO

TUTORES:

VALERO LAPARRA PÉREZ-MUELAS

NURIA ALABAU BOSQUE



VNIVERSITAT
DE VALÈNCIA



Escola Tècnica Superior
d'Enginyeria **ETSE-UV**

TRABAJO FIN DE GRADO

DEEP LEARNING APLICADO A LA CLASIFICACIÓN Y SEGMENTACIÓN DE IMÁGENES DE TUMORES CEREBRALES

AUTOR: JORGE ALBALAT LUENGO

**TUTORES: VALERO LAPARRA PÉREZ-MUELAS
NURIA ALABAU BOSQUE**

Declaración de autoría:

Yo, Jorge Albalat Luengo, declaro la autoría del Trabajo Fin de Grado titulado “Deep Learning aplicado a la clasificación y segmentación de imágenes de tumores cerebrales” y que el citado trabajo no infringe las leyes en vigor sobre propiedad intelectual. El material no original que figura en este trabajo ha sido atribuido a sus legítimos autores.

Valencia, 4 de mayo de 2026

Fdo: Jorge Albalat Luengo

Resumen:

El objetivo de este trabajo es diseñar, entrenar y evaluar modelos de Deep Learning que permitan clasificar tumores cerebrales en imágenes ya sea de Tomografía Computarizada(CT) o de Resonancia Magnética(MRI) como sanas o con tumor para su posterior segmentación de la región tumoral en el caso de las imágenes que son positivas en tumor. La finalidad práctica es servir de apoyo a profesionales para poder diagnosticar y delimitar el tumor en la imagen de la prueba realizada.

El trabajo se distingue en dos partes y la metodología utilizada en cada una de ellas es:

Fase 1. La metodología se centra en la clasificación binaria de las imágenes utilizando Redes Neuronales Convolucionales creadas desde cero y modelos pre-entrenados como son VGG16 y ResNet50 a los cuales se les aplican estrategias de entrenamiento como son Transfer Learning, Fine Tunning y Partial Fine Tunning y con distintas combinaciones de las capas que se congelan del modelo original. Para esta primera fase, se evalúan un total de 14 modelos sobre el conjunto de CT (4618 imágenes) y 14 sobre el de MRI (5000 imágenes).

Fase 2. Una vez escogido el modelo más óptimo de clasificación se pasa a la segmentación en la que se desarrollan modelos en la arquitectura U-Net, utilizando como encoder tanto VGG16 como ResNet34, con el objetivo de delimitar la región tumoral a nivel de píxel sobre un conjunto de 1373 imágenes de MRI con sus máscaras asociadas.

Abstract:

The objective of this work is to design, train and evaluate Deep Learning models capable of classifying brain tumors in images from either Computed Tomography (CT) or Magnetic Resonance Imaging (MRI) as healthy or tumor-bearing, for subsequent segmentation of the tumor region in the case of images that are positive for tumor. The practical aim is to support medical professionals in diagnosing and delineating the tumor within the scan.

The work is divided into two parts, and the methodology employed for each is as follows:

Phase 1. The methodology focuses on binary classification of images using Convolutional Neural Networks built from scratch and pre-trained models such as VGG16 and ResNet50, to which training strategies such as Transfer Learning, Fine Tuning and Partial Fine Tuning are applied with different combinations of frozen layers from the original model. For this first phase, a total of 14 models are evaluated on the CT dataset (4618 images) and 14 on the MRI dataset (5000 images).

Phase 2. Once the optimal classification model is selected, the study proceeds to segmentation, where models based on the U-Net architecture are developed, using both VGG16 and ResNet34 as encoders, with the aim of delineating the tumor region at pixel level on a dataset of 1373 MRI images with their associated masks.

Resum:

L'objectiu d'aquest treball és dissenyar, entrenar i avaluar models de Deep Learning que permeten classificar tumors cerebrals en imatges ja siga de Tomografia computada(CT) o de Ressonància Magnètica(MRI) com a sanes o amb tumor per a la seua posterior segmentació de la regió tumoral en el cas de les imatges que són positives en tumor. La finalitat pràctica és servir de suport a professionals per a poder diagnosticar i delimitar el tumor en la imatge de la prova realitzada.

El treball es distingix en dos parts i la metodologia utilitzada en cada una d'elles és:

Fase 1. La metodologia es centra en la classificació binària de les imatges utilitzant Xarxes Neuronals Convolucionals creades des de zero i models pre-entrenats com són VGG16 i ResNet50 als quals se'ls apliquen estratègies d'entrenament com són Transfer Learning, Fine Tunning i Parcial Fine Tunning i amb diferents combinacions de les capes que es congelen del model original. Per a aquesta primera fase, s'avaluen un total de 14 models sobre el conjunt de CT (4618 imatges) i 14 sobre el de MRI (5000 imatges).

Fase 2. Una vegada triat el model més òptim de classificació es passa a la segmentació en la qual es desenrotllen models en l'arquitectura U-Net, utilitzant com encoder tant VGG16 com ResNet34, amb l'objectiu de delimitar la regió tumoral a nivell de píxel sobre un conjunt de 1373 imatges de MRI amb les seues màscares associades.

Agradecimientos:

En primer lugar quiero agradecer a todos aquellos que me han apoyado durante todos estos años.

En segundo lugar...

Índice general

1. Introducción y/o Antecedentes y/o Estado del arte y/o Motivación	17
1.1. Introducción	17
1.2. Antecedentes	18
1.3. Objetivos	20
1.4. Marco Teórico	21
1.4.1. Métricas utilizadas	21
2. Materiales y métodos	25
2.1. Datos del estudio	25
2.1.1. Dataset de Clasificación	25
2.1.2. Dataset de Segmentación	27
2.2. Diseño experimental	29
2.3. Metodología	29
2.3.1. Arquitecturas para Clasificación	29
2.3.2. Arquitecturas para Segmentación	49
3. Resultados y Discusión	53
3.1. Resultados	53
3.1.1. Modelos de Clasificación	53
3.1.2. Modelos de Segmentación	72
4. Conclusiones y proyección futura.	77
4.1. Conclusiones	77
4.1.1. Conclusiones para Clasificación	77
4.1.2. Conclusiones para Segmentación	78
4.2. Trabajo futuro	79
A. Anexos	81
A.1. Ejemplos del lenguaje de marcado Latex	81
Bibliografía	82

Capítulo 1

Introducción y/o Antecedentes y/o Estado del arte y/o Motivación

1.1. Introducción

Uno de los mayores retos de la medicina moderna es el diagnóstico y tratamiento de los cánceres y tumores. Concretamente los que afectan al cerebro, esto se debe a la complejidad del diagnóstico temprano y su alta tasa de mortalidad. En España este tipo de tumores afecta al año a más de 4.400 personas [1], siendo la tasa de supervivencia a cinco años inferior al 25 % [2], en caso de que no se diagnostique en fases tempranas, esto representa un punto importante para los expertos a la hora de poder salvar la vida de las personas que padecen este tipo de cánceres.

En la medicina actual, el proceso del diagnosis mediante imágenes se realiza con pruebas de Resonancia Magnética (MRI) y Tomografía Computarizada (CT) [3], estas pruebas muestran a los expertos si el paciente tiene estructuras anómalas, y permiten determinar la magnitud del tumor. Sin embargo, esta tarea esta asociada al 100 % al humano, lo que puede hacer que en ciertos casos se cometan errores de diagnóstico debidos a diferentes factores, y de esta manera detectando el tumor en fases más avanzadas.

En este punto es en el que el Machine Learning y el Deep Learning pueden ayudar a los profesionales siendo una herramienta de apoyo pero nunca de sustitución, para poder diagnosticar mejor y más rápido. Las Redes Neuronales Convolucionales (CNN) [4] tienen una gran capacidad para poder extraer características y patrones de imágenes, por lo tanto, la aplicación de las mismas puede mejorar el servicio que se le da al paciente ayudando a salvar más vidas.

En este trabajo se presenta un sistema de ayuda al profesional que consiste en dos etapas: clasificación de imágenes de MRI y CT en sanas o con tumor, y segmentación de los tumores en las imágenes que previamente se han clasificado como imagen con tumor, para ayudar a detectar la zona en la que se realizará el debido tratamiento.

Además, este trabajo muestra una comparación entre distintas estrategias. Por un lado, se han construido modelos personalizados y entrenados desde cero y, por otro lado, se ha aplicado Transfer Learning en modelos ya pre-entrenados como son VGG [5] y ResNet [6], de esta manera se escoge el mejor modelo para realizar la tarea deseada.

1.2. Antecedentes

El diagnóstico de tumores cerebrales ha evolucionado en las últimas décadas. Históricamente se ha diagnosticado la presencia de este tipo de enfermedad en imágenes mediante la habilidad de los médicos, analizando las pruebas visualmente y tomando una decisión en base a su experiencia y conocimiento. Más tarde, se comenzaron a utilizar algoritmos de visión por computación, pero estos métodos tienen ciertas limitaciones.


En este capítulo se describirá el método histórico de diagnosis a través de las imágenes y se explorará como las Redes Neuronales Convolucionales son una alternativa nueva y efectiva que se puede demostrar con las arquitecturas de VGG y ResNet.

El diagnóstico de los tumores cerebrales ha dependido históricamente de dos tipos de pruebas que ofrecen imágenes:

- Tomografía Computarizada (CT): Una de las primeras pruebas en permitir ver el interior del cráneo y, por lo tanto, permitió no solo diagnosticar tumores sino también hemorragias. Es un método que tiene ciertas limitaciones en cuanto a los contrastes y detalles que ofrece en las distintas partes del cerebro, sin embargo, ofrece buena resolución espacial y es rápida de realizar, lo que la hace especialmente útil en situaciones de urgencia [7].




(a) Imagen CT Tumor.




(b) Imagen CT Sana.

Figura 1.1: Imágenes del conjunto de CT.

- Resonancia Magnética (MRI): Actualmente es la prueba que se utiliza para diagnosticar los tumores en el cerebro, ya que permite obtener mayor detalle y diferenciar mejor que en la Tomografía Computarizada en los tejidos blandos lo que permite distinguir con mayor precisión los límites del tumor respecto al tejido sano, además la MRI proporciona imágenes de diferentes ángulos sin necesidad de reposicionar al paciente lo cual hace que la MRI sea mejor que la CT para la detección de tumores cerebrales, especialmente los de pequeño tamaño o los situados en zonas profundas del cerebro [7].



(a) Imágen MRI Tumor.



(b) Imágen CT Sana.

Figura 1.2: Imágenes del conjunto de MRI.

Actualmente como ya se tiene un buen método de hacer la prueba para el diagnóstico, el reto está en la interpretación de la propia prueba, ya que aunque el diagnóstico lo realiza siempre un profesional, este puede llevar a errores, por lo que un sistema automático adicional puede resultar de gran ayuda para los profesionales no solo para el mejor diagnóstico, sino también para la velocidad del mismo.

Este proyecto se centra en el uso de Redes Neuronales Convolucionales (CNN) [4], que a diferencia de las redes neuronales densas tradicionales, usan menos parámetros para extraer las características haciendo que sean muy buenas para el procesamiento de imágenes. [no se si meter aquí la cita]

Concretamente en este trabajo, se utilizan arquitecturas construidas y entrenadas desde cero, pero también se utilizan arquitecturas ya creadas y pre-entrenadas como son:

- VGG16: Es una arquitectura creada en la Universidad de Oxford, la cual se caracteriza por los filtros que usa (3x3) que son pequeños, aunque tiene una gran cantidad de parámetros debido a las capas densas que tiene en la parte final de la estructura. [5]
- ResNet50: Es una arquitectura que soluciona el problema que había con el desvanecimiento del gradiente que impedía el aprendizaje en las primeras capas [otra cita], por eso introdujeron las conexiones residuales, las cuales permiten entrenar estructuras bastante profundas con mayor eficiencia que VGG16. [6]

En la tarea de segmentación se requiere una clasificación a nivel de píxel en lugar de a nivel global (tumor o no), por lo tanto en esta parte del trabajo se han escogido arquitecturas de tipo Encoder-Decoder que tienen dos partes:

- Encoder: Su función es comprimir la imagen reduciendo la dimensionalidad para capturar características principales de la imagen (qué hay).
- Decoder: Su función es volver a obtener la imagen con los detalles originales, permitiendo que se centre más en la localización en este caso del tumor (donde está).

1.3. Objetivos

El principal objetivo de este trabajo es ayudar a profesionales con una herramienta como es la computación, a poder en este caso mejorar el diagnóstico de tumores cerebrales en pacientes detectando y ubicando los propios tumores a través de imágenes.




Figura 1.3: Esquema general del flujo de trabajo. A partir de imágenes de Tomografía Computarizada (CT) y Resonancia Magnética (MRI), se aplican Redes Neuronales Convolucionales para dos tareas: la clasificación de imágenes en sanas o con tumor, y la segmentación de la región tumoral. Los modelos son evaluados y comparados con el objetivo de proporcionar una herramienta de apoyo al diagnóstico médico.

El objetivo general de este trabajo es diseñar, aplicar y evaluar arquitecturas de Deep Learning capaces de clasificar imágenes de Tomografía Computarizada (CT) y de Resonancia Magnética (MRI) en dos clases que son: Sana o Tumor, para posteriormente hacer una segmentación sobre las que tienen tumor, y poder ser más precisos a la hora de ubicar el tumor en el cerebro. Estos procesos se realizan utilizando Redes Neuronales Convolucionales (CNN) construidas y entrenadas desde cero, y también utilizando dos arquitecturas ya creadas y pre-entrenadas con imágenes para poder comparar y escoger el modelo con el mejor rendimiento.

Con el objetivo inicial fijado, los objetivos para las diferentes fases de este trabajo han sido:

1. **Elección y preparación de los datasets:** En primer lugar buscar un dataset que se componga de Tomografías Computarizadas y Resonancias Magnéticas, para el entrenamiento y la predicción en los modelos de clasificación. Por otro lado, otro dataset que contenga imágenes de Resonancias Magnéticas para el entrenamiento y la predicción de las arquitecturas utilizadas en segmentación. Finalmente en este punto se ha realizado un pre-procesamiento de los datos para mejorar la capacidad de generalización de los modelos aumentando su rendimiento a la hora de predecir.
2. **Desarrollo y evaluación de los modelos en la clasificación:** Construir una Red Neuronal Convolutiva (CNN) para entrenarla desde cero y predecir sobre cada uno de los datasets de clasificación, que se separan según el tipo de la prueba realizada (Tomografía Computarizada o Resonancia Magnética). Por otro lado, utilizar las arquitecturas ya creadas VGG y ResNet de tres formas distintas: prediciendo sin haber entrenado con los datos del estudio, entrenando todos los parámetros de cada una de las arquitecturas para poder predecir más tarde y, finalmente aplicando Transfer Learning congelando varios conjuntos de capas convolucionales para mejorar el resultado lo máximo posible. El objetivo es obtener el mejor resultado posible de los modelos citados, por lo que se realizan varias pruebas en las que se intenta mejorar el resultado del entrenamiento y de la predicción. Finalmente, se comparan resultados y se escoge el mejor modelo entre los entrenados.
3. **Desarrollo y evaluación de los modelos en la segmentación:** Construir una arquitectura que se base en un método de Encoder-Decoder para poder delimitar el tumor dentro de la imagen, entrenándola desde cero para predecir sobre el conjunto de datos que hay para segmentación. Por otro lado, utilizar las arquitecturas ya creadas y entrenadas que son las arquitecturas de VGG16 y ResNet34 de tres formas distintas: prediciendo sin haber entrenado con los datos del estudio, entrenando todos los parámetros de cada una de las arquitecturas para poder predecir más tarde y, finalmente aplicando Transfer Learning congelando varios conjuntos de capas convolucionales para mejorar el resultado lo máximo posible. El objetivo es obtener el mejor resultado posible de los modelos citados, por lo que se realizan varias pruebas en las que se intenta mejorar el resultado del entrenamiento y de la predicción. Finalmente, se comparan resultados y se escoge el mejor.
4. **Comparar las distintas estrategias y modelos utilizados:** El objetivo final de este trabajo es comparar cuantitativamente mediante métricas las estrategias utilizadas ya sea Transfer Learning, entrenar los modelos completos o construirlos desde cero, con el fin de escoger la estrategia que ayude al profesional a diagnosticar y ubicar los tumores en las imágenes de las pruebas realizadas.

1.4. Marco Teórico

1.4.1. Métricas utilizadas

Curvas de entrenamiento Se tienen dos curvas de entrenamiento, la primera de las curvas es la de accuracy, esta curva muestra el porcentaje de imágenes que el modelo ha clasificado bien en cada época, por lo que cuanto más alta mejor, en esta

gráfico a su vez hay dos curvas, una que muestra el accuracy sobre el conjunto de entrenamiento (porcentaje de imágenes clasificadas bien en el conjunto de entrenamiento) y la segunda curva es la de validación que muestra el porcentaje de imágenes bien clasificadas sobre el conjunto de validación.

Por otro lado, se tienen las curvas de pérdida, en el caso de este trabajo las funciones de pérdida que se han utilizado para la clasificación han sido todas la misma función que es la de Binary Crossentropy, lo que muestra esta función es la seguridad o confianza con la que el modelo predice la imagen, es decir, cuanto más seguro esté el modelo de que una imagen tiene tumor (predecirá con por ejemplo 0.99) el la función de pérdida será mas baja, por lo que cuanto más baja sea esta curva mejor. Al igual que en el gráfico de accuracy habia dos curvas en este lo mismo, la curva del conjunto de entrenamienot y la curva del conjunto de validación. El uso que tienen estas curvas es para evaluar el entrenamiento del modelo comprobar que ha aprendido correctamente y que no hay overfitting.

Matriz de confusión Este gráfico muestra como ha clasificado el modelo cada imagen y lo que en realidad era esa imagen, es decir, que en este gráfico se ve cuantas imágenes el modelo clasifica bien cuales y mal de forma cuantificable. En este gráfico se pueden ver cuantas imágenes son falsos negativos (predice sano cuando hay tumor) y cuantas falsos positivos (predice tumor cuando no lo hay), esto muestra la importancia de esta métrica ya que se podría ver cuanta gente se podría quedar sin tratamiento cuando en realidad tiene tumor (falsos negativos).

Para poder evaluar y comparar de forma objetiva el rendimiento de los distintos modelos de clasificación entrenados en este trabajo, se han utilizado varias métricas derivadas de la matriz de confusión. La matriz de confusión es una tabla que organiza las predicciones del modelo en cuatro categorías: verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN). A partir de estas cuatro cantidades se definen las siguientes métricas:

Accuracy Mide la proporción total de predicciones correctas sobre el conjunto evaluado. Se calcula como:

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN} \quad (1.1)$$

Aunque es una métrica intuitiva, puede resultar engañosa cuando las clases están desbalanceadas, ya que un modelo que prediga siempre la clase mayoritaria puede obtener un accuracy alto sin haber aprendido realmente a distinguir las clases.

Binary Crossentropy Binary Cross-Entropy (Entropía cruzada binaria). Es la función de pérdida utilizada durante el entrenamiento de todos los modelos de clasificación de este trabajo. Mide la distancia entre la distribución de probabilidad predicha por el modelo y la distribución real (la etiqueta). Para una clasificación binaria con probabilidad predicha $\hat{p}$ y etiqueta real $y \in \{0, 1\}$:

$$\text{BCE} = -[y \cdot \log(\hat{p}) + (1 - y) \cdot \log(1 - \hat{p})] \quad (1.2)$$

Cuanto menor es este valor, más seguras y correctas son las predicciones del modelo. En las curvas de entrenamiento se muestra esta pérdida a lo largo de las épocas tanto para el conjunto de entrenamiento como para el de validación, lo que permite detectar problemas de sobreajuste cuando la pérdida de validación empieza a aumentar mientras la de entrenamiento sigue disminuyendo.

IoU Score El IoU Score (Intersection over Union) o Índice de Jaccard es la métrica principal utilizada para evaluar los modelos de segmentación de este trabajo, esta métrica mide el solapamiento entre la máscara predicha por el modelo ($\hat{M}$) y la máscara real (M), calculándose como la división entre la intersección y la unión de ambas máscaras a nivel de píxel:

$$\text{IoU} = \frac{|\hat{M} \cap M|}{|\hat{M} \cup M|} = \frac{VP}{VP + FP + FN} \quad (1.3)$$

Un valor de IoU de 1 indica un solapamiento perfecto entre la máscara predicha y la real, mientras que 0 indica que no hay ningún solapamiento. Es una métrica más estricta que el Dice Score, ya que penaliza más los casos de solapamiento parcial.

Dice Score El Dice Score (Coeficiente de Sørensen-Dice) es equivalente al F1-Score pero aplicado a nivel de píxel, esta métrica mide la similitud entre la máscara predicha y la real, siendo menos estricto que el IoU ante solapamientos parciales:

$$\text{Dice} = \frac{2 \cdot |\hat{M} \cap M|}{|\hat{M}| + |M|} = \frac{2 \cdot VP}{2 \cdot VP + FP + FN} \quad (1.4)$$

La relación entre ambas métricas es la mostrada en la Ecuación 1.5, por lo que el Dice Score siempre es mayor o igual que el IoU para un mismo modelo. Valores próximos a 1 indican una delimitación muy precisa del tumor.

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}} \quad (1.5)$$

BCE + Jaccard Loss La Pérdida combinada de Binary Cross-Entropy y Jaccard es la función de pérdida utilizada durante el entrenamiento de los modelos de segmentación de este trabajo. En segmentación, a diferencia de la clasificación, existe un problema de desbalanceo a nivel de píxel (en la mayoría de las imágenes, los píxeles pertenecientes al tumor son una minoría frente a los píxeles de fondo sano) por lo que utilizar únicamente Binary Cross-Entropy (Ecuación 1.2) haría que el modelo tendiera a predecir todo como fondo lo que haría que se obtuviese una pérdida baja pero sin detectar realmente el tumor. Por ello, se combina con la pérdida de Jaccard ($1 - \text{IoU}$), que penaliza directamente el bajo solapamiento entre la máscara predicha y la real:

$$\mathcal{L} = \text{BCE} + (1 - \text{IoU}) \quad (1.6)$$

Esta combinación permite que el modelo mejore simultáneamente la confianza en cada píxel y la forma global de la máscara generada, obteniendo resultados superiores a los que se conseguirían utilizando una única función de pérdida.

Capítulo 2

Materiales y métodos

2.1. Datos del estudio

En este trabajo se utilizan dos datasets públicos obtenidos de la plataforma de Kaggle uno para cada una de las dos partes principales del trabajo, a continuación se describen cada uno de ellos:

2.1.1. Dataset de Clasificación

En esta primera parte se utiliza un dataset público de la plataforma de Kaggle [8]. Lo que se busca en esta primera fase es la clasificación binaria de las imágenes en sanas y con Tumor, por lo que el conjunto de datos que se utiliza contiene imágenes sanas y con tumor cerebral de pruebas de Tomografía Computarizada (CT) y de Resonancia Magnética (MRI) que contienen varios tipos de tumor cerebral como son glioma o meningioma aunque este trabajo se centra en la clasificación binaria de si hay o no tumor en las imágenes. La elección del conjunto de datos con los dos tipos de pruebas, es para la comparación de resultados, aunque en la parte de segmentación se utiliza el estándar de las pruebas de imágenes cerebrales ya que tiene más detalles.

Este conjunto de datos tiene un tamaño de 9618 imágenes las cuales se separan en Tomografía Computarizada y Resonancia Magnética, debido a que se pretende entrenar y crear modelos especializados en un tipo de prueba ya que de esta manera se obtienen mejores resultados debido a las características de cada imagen. Por lo tanto, en el conjunto de CT hay 4618 imágenes de las cuales hay 2300 que son de un cerebro sano y 2318 que son de un cerebro con tumor. Para el conjunto de Resonancia Magnética hay 5000 imágenes, de las cuales son 2000 de un cerebro sano y 3000 con tumor.

Cuadro 2.1: Distribución del dataset de clasificación por tipo de prueba y clase.

Conjunto	Sano	Tumor	Total
CT	2300	2318	4618
MRI	2000	3000	5000
Total	4300	5318	9618

Las imágenes de este conjunto de datos presentan dimensiones variables sin un tamaño estándar entre ellas. En la Tabla 2.2 se muestran algunos ejemplos de las dimensiones originales.

Cuadro 2.2: Ejemplos de dimensiones originales del dataset de clasificación.

Ejemplo	Dimensiones	Canales
1	504×540	RGB
2	630×630	RGB
3	300×168	RGB
4	253×239	RGB
5	225×225	RGB

Esta variabilidad hace necesario un preprocesamiento para homogeneizar todas las imágenes. En primer lugar, aquellas imágenes que no se encuentran en formato RGB se convierten a este formato para garantizar que todas tengan 3 canales de color. A continuación, se redimensionan a un tamaño fijo de 256×256 píxeles para que tengan un buen detalle en cuanto a la información de la imagen pero que no sea demasiado costoso entrenar los modelos, es decir, se busca un equilibrio entre rendimiento del modelo y consumo. Finalmente, los valores de los píxeles se normalizan al rango $[0, 1]$ dividiendo entre 255, lo que facilita la convergencia durante el entrenamiento de los modelos.

Cada conjunto se ha dividido en primer lugar en dos subconjuntos con una proporción 80/20, separando un 20 % de los datos como conjunto de test. Posteriormente, durante el entrenamiento se reserva un 20 % del conjunto de entrenamiento como conjunto de validación por lo que quedan unos porcentajes de 64/16/20.


Cuadro 2.3: División en conjuntos de entrenamiento, validación y test para clasificación.

Conjunto	Entrenamiento (64 %)	Validación (16 %)	Test (20 %)	Total
CT	2956	738	924	4618
MRI	3200	800	1000	5000

En las Figuras 2.1 y 2.2 se muestran ejemplos representativos de ambos conjuntos de datos.




(a) Imágen CT Tumor.




(b) Imágen CT Sana.

Figura 2.1: Imágenes del conjunto de CT para clasificación.



(a) Imágen MRI Tumor.



(b) Imágen CT Sana.

Figura 2.2: Imágenes del conjunto de MRI para clasificación.

2.1.2. Dataset de Segmentación

Para la segunda parte de este trabajo se han utilizado imágenes pertenecientes a un dataset específico de segmentación donde cada imagen tiene su máscara asociada, este dataset también se ha obtenido de la página de Kaggle [9] con origen en el proyecto del artículo Comprehensive, Integrative Genomic Analysis of Diffuse Lower-Grade Gliomas [10].

A diferencia del dataset anterior que se utiliza para la clasificación, este dataset solamente contiene imágenes de 110 pacientes de Resonancias Magnéticas ya que son el estándar de pruebas que se realizan para el diagnóstico de los tumores cerebrales ya que es en la prueba en la que se obtienen mejores detalles. Además, otra de las diferencias que tiene este dataset es que tiene las máscaras de la región del tumor que han sido delimitadas por profesionales.

El conjunto de datos tiene 3929 de las cuales con tumor hay 1373, el conjunto final que se utiliza para la segmentación es el de 1373 imágenes que tienen tumor (imágenes con la máscara no totalmente negra). Como este conjunto de datos ha sido utilizado en un trabajo ya el preprocesamiento ya está hecho, todas tienen las mismas dimensiones (256x256) al igual que sus máscaras.

Cuadro 2.4: Distribución del dataset de segmentación.


Categoría	Imágenes
Total de imágenes	3929
Imágenes sin tumor (descartadas)	2556
Imágenes con tumor (utilizadas)	1373
Número de pacientes	110

Cada conjunto se ha dividido en primer lugar en dos subconjuntos con una proporción 80/20, separando un 20 % de los datos como conjunto de test. Posteriormente, durante el entrenamiento se reserva un 20 % del conjunto de entrenamiento como conjunto de validación por lo que quedan unos porcentajes de 64/16/20.

Cuadro 2.5: División en conjuntos de entrenamiento, validación y test para segmentación.

Entrenamiento (64 %)	Validación (16 %)	Test (20 %)	Total
878	220	275	1373

En la Figura 2.3 se muestra un ejemplo de una imagen de MRI junto con su máscara de segmentación asociada.



(a) Imágen de MRI Tumor del conjunto de segmentación.



(b) Imágen de MRI Máscara del conjunto de segmentación.

Figura 2.3: Imágenes del conjunto de MRI para segmentación.

2.2. Diseño experimental

2.3. Metodología

Para cumplir con los objetivos planteados en este trabajo, la metodología que se ha seguido esta dividida en dos etapas principales. En la primera etapa se utilizan para entrenar y predecir sobre imágenes de CT (Tomografía Computarizada) y MRI (Resonancia Magnética) redes neuronales convolucionales (CNN) diseñados en el propio trabajo y modelos ya creados y pre-entrenados para hacer Transfer Learning y con el objetivo de compararlos. Posteriormente, en la segunda fase de este trabajo se utilizan otros modelos también construidos en este trabajo y otros pre-entrenados para la segmentación de la región tumoral en las imágenes de MRI. En este punto se van a explicar las arquitecturas de redes convolucionales y los métodos de entrenamiento de los modelos aplicados.

2.3.1. Arquitecturas para Clasificación

En esta primera etapa se trata de determinar si las imágenes de las dos pruebas diferentes son sanas o tienen tumor, para ello se han seguido dos estrategias.

Conjunto de CT

Modelo Propio: Se han diseñado 4 Redes Neuronales Convolucionales en las que se ha ido modificando tanto la estructura como los parámetros de entrenamiento.

Los cuatro modelos tienen una entrada de 256×256 , el primero de los cuatro modelos tiene dos capas convolucionales en los que en cada uno de ellos hay una Convolution2D con filtros de 3×3 y con una función de activación ReLu, la primera capa de

convolución tiene 8 filtros y la segunda capa tiene 16 filtros, ambos tienen una capa de MaxPooling(2x2) para reducir la dimensionalidad a la mitad después de cada uno de las capas de convolución. Después de las capas convolucionales se aplica una capa de Flatten para vectorizar los datos y dos capas Densas, una capa oculta con 4 neuronas y función de activación ReLu y finalmente la capa de salida con 1 neurona para la clasificación binaria con una función de activación Sigmoid.




Figura 2.4: Arquitectura **CNN-CT-Base**. Entrada de 256x256x3 procesada por dos capas Conv2D (8 y 16 filtros), reduciendo la resolución a 62x62 tras MaxPooling. El vector aplanado de 61.504 valores se comprime a 4 neuronas Dense con ReLU y una salida Sigmoid.

En el segundo de los modelos que se construye para intentar mejorar el rendimiento, se añade al modelo **CNN-CT-Base** que tenía dos capas convolucionales una con 8 filtros y otra con 16, otra tercera capa de Convolution2d con función de activación ReLu que tiene 8 filtros con filtros de 3x3 y una capa de MaxPooling(2x2), además en esta arquitectura lo que se ha hecho ha sido después de cada capa de convolución añadir un Dropout con probabilidad de 0.5. Finalmente se aplica un Flatten para vectorizar y dos capas Densas igual que en el modelo **CNN-CT-BASE** con una capa oculta con 4 neuronas y función de activación ReLu y la capa de salida con 1 neurona para la clasificación binaria con una función de activación Sigmoid.




Figura 2.5: Arquitectura **CNN-CT-Drop**. Tres capas Conv2D (8, 16 y 8 filtros) con Dropout del 50 % tras cada bloque para regularización. La resolución se reduce de 254x254 a 30x30, generando un vector aplanado de 7.200 valores conectado a una capa Dense de 4 neuronas y salida Sigmoid.

Para el tercer modelo la primera capa convolucional tiene 16 filtros de 3x3 con una función de activación ReLu, la segunda capa de convolución tiene 32 filtros con filtros de 3x3 y también función de activación ReLu, le sigue otra capa de 64 filtros con filtros de 3x3 con función de activación ReLu, el cuarto de las capas convolucionales tiene 128 filtros de 3x3 con la misma función de activación que los anteriores, le sigue una capa de 64 filtros 3x3 y función de activación ReLu y finalmente la última capa convolucional tiene 32 filtros con filtros de 3x3 y la función de activación también ReLu. Entre cada uno de las capas convolucionales hay una capa de MaxPooling(2x2) y se ha aplicado Dropout después de cada capa de Maxpooling con probabilidad de 0.35. Una vez aplicada la convolución se ha hecho Flatten para vectorizar los resultados y se han aplicado dos capas Densas, la primera capa oculta con 32 neuronas y función de activación ReLu y la capa de salida con 1 neurona para la clasificación binaria con una función de activación Sigmoid.




Figura 2.6: Arquitectura **CNN-CT-Deep**. Seis capas Conv2D en forma de embudo (16, 32, 64, 128, 64 y 32 filtros) con Dropout del 35 %. La resolución se reduce progresivamente de 254x254 a 2x2, produciendo un vector de solo 128 valores. Una capa Dense de 32 neuronas precede a la salida Sigmoid.

Finalmente, para los modelos creados en el conjunto de CT se ha realizado una última prueba para intentar obtener un mejor rendimiento, es la misma estructura que [CNN-CT-Deep](#), lo que se ha cambiado en este paso ha sido el Learning Rate y las épocas a la hora de entrenar el modelo, en el anterior se tenía un Learning Rate de 0.001 y se entrenaban 85 épocas, por otro lado, en este modelo se ha probado a entrenar con un Learning Rate de 0.0001 y 200 épocas.




Figura 2.7: Arquitectura **CNN-CT-Deep**. Seis capas Conv2D en forma de embudo (16, 32, 64, 128, 64 y 32 filtros) con Dropout del 35 %. La resolución se reduce progresivamente de 254x254 a 2x2, produciendo un vector de solo 128 valores. Una capa Dense de 32 neuronas precede a la salida Sigmoid.

Modelos Pre-entrenados El primero de los modelos pre-entrenados que se usa es el

modelo de VGG16, es un modelo que utiliza filtros de 3x3, tiene 5 bloques convolucionales, en el primer bloque convolucional hay dos capas de Convolución2D con 64 filtros con filtros de 3x3, el segundo bloque tiene dos capas de Convolución2D con 128 filtros con filtros de 3x3 cada una de las capas, el tercer bloque tiene 3 capas de Convolución con 256 filtros cada una con filtros de 3x3, el cuarto bloque convolucional tiene también 3 capas convolucionales de 512 filtros cada una con filtros de 3x3 y finalmente el último bloque convolucional tiene también 3 capas de Convolución2D con 512 filtros cada una y con filtros de 3x3. Después de cada bloque de convolución hay una capa de MaxPooling. Finalmente, después de las convoluciones tiene una parte de capas densas que en este trabajo se ha sustituido para poder adaptar más el modelo al problema que se ha planteado.

Se han seguido diferentes metodologías con este modelo para las diferentes pruebas que se han realizado. La primera de ellas consiste en sustituir las capas densas finales del modelo original por una capa de Global Average Pooling 2D, una capa densa con 16 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria, se ha entrenado el resto del modelo entero, sin congelar ninguna capa de los bloques convolucionales. Se ha entrenado con 30 épocas, un learning rate de 0.001 con el optimizador Adam. [11]




Figura 2.8: Arquitectura **VGG16-FT (CT)**. Los 5 bloques convolucionales de VGG16 se re-entrenan completamente sobre el conjunto de CT. La salida se reduce mediante Global Average Pooling a 512 valores, conectados a una capa Dense de 16 neuronas y salida Sigmoid.

Para la segunda prueba realizada, se han sustituido de nuevo las capas densas finales del modelo original de VGG16 por una capa de Global Average Pooling 2D, una primera capa densa con 128 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. Para este modelo se ha optado por realizar la técnica de Transfer Learning, se han congelado todas las capas convolucionales para no realizar cambios en los pesos y solamente se están entrenando las capas densas que se han añadido, por lo que es más rápido de entrenar y también se utilizan los pesos que ya tiene el modelo que está pre-entrenado

evitando el riesgo al over fitting. Se ha entrenado con 50 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.9: Arquitectura **VGG16-TL (CT)**. Los 5 bloques convolucionales permanecen congelados (en gris) con los pesos de ImageNet. Solo se entrenan las capas Dense (128 y 32 neuronas) sobre el conjunto de CT.

En el tercer modelo probado, se han sustituido las capas densas finales del modelo original de VGG16 por una capa de Global Average Pooling 2D, una primera capa densa con 256 neuronas y función de activación ReLu, una capa densa con 128 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoid para la clasificación binaria. Para este modelo se ha optado por realizar la técnica de Partial Fine Tunning, es decir, se han congelado algunas de las capas convolucionales para no realizar cambios en los pesos y se están entrenando el resto de capas convolucionales y las capas densas que se han añadido, concretamente se han congelado 17 de las capas convolucionales, por lo que es más rápido de entrenar que el modelo completo (**VGG16-FT-CT**) pero se tiene una mayor adaptación al problema que el modelo en el que se han congelado todas las capas (**VGG16-TL-CT**), además las capas iniciales actúan como extractores de características de bajo nivel aprendiendo a identificar patrones, por lo que se dejan sin entrenar y se entrenan capas mas bajas. Se ha entrenado con 35 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.10: Arquitectura **VGG16-PFT-17 (CT)**. Las 17 primeras capas congeladas cubren los bloques 1-4 y dos Conv del bloque 5. Solo la última capa convolucional del bloque 5 se re-entrena junto con las capas Dense (256, 128 y 32 neuronas) sobre el conjunto de CT.

Con el objetivo de seguir mejorando el resultado a la hora de predecir se han realizado dos pruebas más con la prueba de Parcial Fine Tunning. La primera de ellas consiste en congelar una capa convolucional más que en la prueba anterior (**VGG16-PFT17-CT**), es decir, se han congelado 18 capas convolucionales, de esta manera se mantienen una cantidad bastante mayor de pesos originales del modelo. Las capas densas que se han añadido han sido una primera capa densa con 256 neuronas y función de activación ReLu, una capa densa con 128 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 40 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.11: Arquitectura **VGG16-PFT-18 (CT)**. Las 18 primeras capas congeladas cubren todos los bloques convolucionales. Solo se entrenan las capas Dense (256, 128 y 32 neuronas) sobre el conjunto de CT.

Finalmente, para este modelo pre-entrenado se ha realizado una última prueba que consiste en Fine Tunning Parcial, pero en este caso se han congelado 16 capas convolucionales con el objetivo de mejorar los resultados anteriores (**VGG16-PFT17-CT**, **VGG16-PFT18-CT**) haciendo que el modelo este más adaptado a los datos que se

están utilizando. En la parte final del modelo se ha añadido una primera capa densa con 256 neuronas y función de activación ReLu, una capa densa con 128 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 25 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.12: Arquitectura **VGG16-PFT-16 (CT)**. Las 16 primeras capas congeladas cubren los bloques 1-4 y una Conv del bloque 5. Las dos últimas capas convolucionales del bloque 5 se re-entrenan junto con las capas Dense (256, 128 y 32 neuronas) sobre el conjunto de CT.

El segundo de los modelos pre-entrenados que se ha utilizado es ResNet50 [6], un modelo que es más complejo que el anterior **VGG16-FT-CT** lo que permite entrenar redes más profundas sin tener problemas con la desaparición del gradiente. El modelo tiene cuatro grandes bloques convolucionales, el primero de ellos está formado por tres capas convolucionales en las que las dos primeras tienen 64 filtros y la salida tiene 256 filtros, el segundo de ellos tiene 3 capas convolucionales en las que se ha aumentado la profundidad del modelo con 2 capas de 128 filtros y una última con 512 filtros, el tercer bloque convolucional del modelo sigue aumentando la profundidad con 3 capas convolucionales con 2 capas de 256 filtros cada una y una final de 1024 filtros, finalmente el último bloque convolucional contiene 3 capas convolucionales que extraen características más complejas con un total de 512 filtros las dos primeras y 2048 filtros la última de ellas. Después de los bloques convolucionales hay un Global Average Pooling y una capa densa final de 1000 neuronas la cual se ha sustituido por una nueva cabecera personalizada para poder adaptar el modelo a las necesidades específicas del problema de clasificación planteado.

En este conjunto de datos la primera solución propuesta con este modelo ha sido aplicando la técnica de Fine Tuning, es decir, se ha entrenado el modelo completo cambiando los pesos que tenía el modelo y adaptándolo al problema y al conjunto de datos. En este modelo se han sustituido las capas finales Densas por una primera capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 15 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.13: Arquitectura **ResNet50-FT (CT)**. Los bloques residuales de ResNet50 (3, 4, 6 y 3 bloques bottleneck) se re-entrenan completamente sobre el conjunto de CT. Global Average Pooling reduce la salida a 2.048 valores, seguidos de tres capas Dense (128, 64 y 32 neuronas) y salida Sigmoid.

Para la segunda solución propuesta se ha optado por realizar la técnica de Transfer Learning, se han congelado todas las capas convolucionales para no realizar cambios en los pesos y solamente se están entrenando las capas densas que se han añadido, por lo que es más rápido de entrenar que **RESNET50-FT-CT** y también se utilizan los pesos que ya tiene el modelo que está pre-entrenado evitando el riesgo al over fitting. En este caso se ha añadido igual que en la solución anterior (**RESNET50-FT-CT**) una primera capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 80 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.14: Arquitectura **ResNet50-TL (CT)**. Todos los bloques residuales permanecen congelados (en gris) con los pesos de ImageNet. Solo se entrenan las tres capas Dense (128, 64 y 32 neuronas) sobre el conjunto de CT.

Para la tercera prueba que se ha realizado, se ha optado por hacer un Transfer Learning en dos pasos, es decir, se han entrenado en la primera fase las capas añadidas que consisten en una primera capa densa con 128 neuronas y función de

activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. Una vez que la nueva cabecera de clasificación está entrenada en la primera fase, se procede a una segunda fase que consiste en hacer Fine Tunning del modelo completo, es decir, entrenar las capas ya entrenadas en la fase previa con las convolucionales congeladas anteriormente, esto se hace con el objetivo de especializar el modelo. El modelo se ha entrenado con 80 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy la primera vez y con 50 épocas, un learning rate de 0.00001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.15: Arquitectura **ResNet50-TL2 (CT)**. Transfer Learning en dos pasos: primero se entrenan solo las capas Dense con el encoder congelado, y después se descongelan todos los bloques y se re-entrena la red completa con un learning rate reducido sobre el conjunto de CT.

La cuarta solución propuesta con este modelo para este conjunto de datos consiste en Parcial Fine Tunning, es decir, que se han congelado en este caso 143 capas convolucionales en para poder conservar pesos que ya tenía el modelo y por otro lado, poder ajustar el modelo más a los datos que se tienen. Por otro lado, se han añadido para la cabecera final de capas densas una primera capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 50 épocas, un learning rate de 0.0001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.16: Arquitectura **ResNet50-PFT-143 (CT)**. Las 143 primeras capas congeladas cubren hasta el primer bloque residual del bloque 5. Los dos últimos bloques residuales (en azul) se re-entrenan junto con las capas Dense (128, 64 y 32 neuronas) sobre el conjunto de CT.

Finalmente la última prueba realizada para este conjunto de datos consiste en Parcial Fine Tuning también igual que la anterior([RESNET50-PFT143-CT](#)) pero se ha decidido congelar muchas menos capas para poder adaptar más los pesos a los datos, concretamente se han congelado 80 capas. Por otro lado, las capas densas que se han añadido han sido como en el resto de las soluciones con este modelo una primera capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 26 épocas, un learning rate de 0.0001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.17: Arquitectura **ResNet50-PFT-80 (CT)**. Las 80 primeras capas congeladas cubren hasta tres bloques residuales del bloque 3. El último bloque residual del bloque 3 (en azul), junto con los bloques 4 y 5 completos, se re-entrenan con las capas Dense (128, 64 y 32 neuronas) sobre el conjunto de CT.

Conjunto de MRI

Modelo Propio: Se han diseñado 3 Redes Neuronales Convolucionales en las que se ha ido modificando tanto la estructura como los parámetros de entrenamiento.

Los tres modelos tienen una entrada de 256×256 , el primero de los tres modelos tiene dos capas convolucionales en los que en cada uno de ellos hay una Convolution2D con filtros de 3×3 y con una función de activación ReLu, la primera capa de convolución tiene 8 filtros y la segunda capa tiene 16 filtros, ambos tienen una capa de MaxPooling(2×2) para reducir la dimensionalidad a la mitad después de cada uno de las capas de convolución. Después de las capas convolucionales se aplica una capa de Flatten para vectorizar los datos y dos capas Densas, una capa oculta con 8 neuronas y función de activación ReLu y finalmente la capa de salida con 1 neurona para la clasificación binaria con una función de activación Sigmoide. El modelo se ha entrenado con 20 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.18: Arquitectura **CNN-MRI-Base**. Misma estructura que CNN-CT-Base con dos capas Conv2D (8 y 16 filtros), pero con una capa Dense de 8 neuronas en lugar de 4, adaptada al conjunto de datos de resonancia magnética.

En el segundo de los modelos que se construye para intentar mejorar el rendimiento de **CNN-MRI-BASE**, este modelo consiste en primera capa de convolución tiene 8 filtros, la segunda capa tiene 16 filtros, la tercera 32 filtros y la última capa convolucional 16 filtros, todas estas capas son de Convolution2d con función de activación ReLu con filtros de 3×3 y una capa de MaxPooling(2×2) y un Dropout con probabilidad de 0.2 después de cada capa convolucional. Finalmente se aplica un Flatten para vectorizar y dos capas Densas igual que en el modelo **CNN-MRI-BASE** con una capa oculta con 4 neuronas y función de activación ReLu y la capa de salida con 1 neurona para la clasificación binaria con una función de activación Sigmoide. El modelo se ha entrenado con 60 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.19: Arquitectura **CNN-MRI-Drop**. Cuatro capas Conv2D (8, 16, 32 y 16 filtros) con Dropout del 20% tras cada bloque. La resolución se reduce de 254x254 a 14x14, generando un vector de 3.136 valores conectado a una capa Dense de 4 neuronas y salida Sigmoid.

El último de los modelos construidos para este conjunto de datos consiste en primera capa de convolución tiene 8 filtros, la segunda capa tiene 16 filtros, la tercera 32 filtros, le sigue una capa con 64 filtros, otra capa con 128 filtros, otra con 64 filtros y una última capa convolucional con 32 filtros, todas estas capas son de Convolucion2d con función de activación ReLu con filtros de 3x3 y una capa de MaxPooling(2x2) y un Dropout con probabilidad de 0.2 después de cada capa convolucional. Finalmente se aplica un Flatten para vectorizar y dos capas Densas igual que en el modelo [CNN-MRI-BASE](#) con una capa oculta con 8 neuronas y función de activación ReLu y la capa de salida con 1 neurona para la clasificación binaria con una función de activación Sigmoid. El modelo se ha entrenado con 130 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.20: Arquitectura **CNN-MRI-Deep**. Siete capas Conv2D en embudo (8, 16, 32, 64, 128, 64 y 32 filtros) con *padding same* y Dropout del 20 %. La resolución decrece de 256x256 a 2x2, produciendo un vector de 128 valores. Una capa Dense de 8 neuronas precede a la salida Sigmoid.

Modelos Pre-entrenados Los modelos pre-entrenados que se han utilizado en este conjunto de datos han sido los mismos que con el conjunto de datos de CT, es decir, se han utilizado el modelo VGG16 y ResNet50. Para el primer modelo pre-entrenado utilizado que es el VGG16 se han propuesto 6 soluciones con diferentes estrategias. La primera de ellas consiste en Fine Tunning, es decir, se han re-entrenado todos los pesos que tenía ya el modelo para poder adaptar los pesos al problema propuesto, también se han entrenado las capas densas finales que se han añadido para sustituir las que trae el modelo. En este caso, las capas densas que se han añadido después de las capas convolucionales que ya trae el modelo son una capa de Global Average Pooling2D, una capa densa oculta con 16 neuronas y función de activación ReLu y una última capa de salida con 1 neurona para la clasificación binaria con una función de activación Sigmoide. El modelo se ha entrenado con 30 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.21: Arquitectura **VGG16-FT (MRI, lr=0.001)**. Los 5 bloques convolucionales de VGG16 se re-entrenan completamente sobre el conjunto de MRI con learning rate de 0.001. Global Average Pooling reduce la salida a 512 valores, seguidos de una capa Dense de 16 neuronas y salida Sigmoid.

Para la segunda solución propuesta se ha utilizado la misma técnica que en la primera solución(**VGG16-FT-MRI**), además se ha utilizado la misma cabecera final, por lo que lo único que cambia respecto a la primera solución son las épocas y el learning rate, esto se ha hecho mirando la curva de entrenamiento para poder obtener un mejor resultado a la hora de predecir. El modelo se ha entrenado con 10 épocas, un learning rate de 0.0001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.22: Arquitectura **VGG16-FT (MRI, lr=0.0001)**. Misma arquitectura que el modelo anterior pero entrenada con un learning rate diez veces menor (0.0001), lo que permite un ajuste más fino de los pesos sobre el conjunto de MRI.

En la tercera solución propuesta se ha utilizado la técnica de Transfer Learning,

es decir, que se han congelado todas las capas convolucionales con los pesos que tiene el modelo, de esta manera el entrenamiento es más rápido y solamente se están entrenando las capas densas que se han añadido, por lo que es más rápido de entrenar que **VGG16-FT-MRI** evitando el riesgo al over fitting. En este caso las capas que se han añadido han sido una primera capa densa con 128 neuronas y función de activación ReLu, una segunda capa densa con 32 neuronas y función de activación ReLu y una última capa densa con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 50 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.23: Arquitectura **VGG16-TL (MRI)**. Los 5 bloques convolucionales permanecen congelados (en gris) con los pesos de ImageNet. Solo se entrenan las capas Dense (128 y 32 neuronas) sobre el conjunto de MRI.

Para la cuarta solución propuesta se ha decidido tomar la técnica de Parcial Fine Tunning, es decir, que se han congelado en este caso 17 capas convolucionales en para poder conservar pesos que ya tenía el modelo y por otro lado, poder ajustar el modelo más a los datos que se tienen. Las capas densas que se han añadido en la cabecera final han sido una capa de Global Average Pooling, una capa densa con 256 neuronas y función de activación ReLu, una capa densa con 128 neuronas y función de activación ReLu, la tercera capa densa añadida tiene 32 neuronas y función de activación ReLu y una capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 20 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.24: Arquitectura **VGG16-PFT-17 (MRI)**. Las 17 primeras capas congeladas cubren los bloques 1-4 y dos Conv del bloque 5. Solo la última capa convolucional del bloque 5 se re-entrena junto con las capas Dense (256, 128 y 32 neuronas) sobre el conjunto de MRI.

En esta quinta solución propuesta también se ha hecho Parcial Fine Tunning igual que **VGG16-PFT17-MRI**, en este caso se han congelado 18 capas, se han congelado más capas para poder conservar más pesos originales del modelo pre-entrenado y evitar el overfitting. Las capas densas que se han añadido a la cabecera final han sido una capa de Global Average Pooling, una capa densa con 256 neuronas y función de activación ReLu, una capa densa con 128 neuronas y función de activación ReLu, la tercera capa densa añadida tiene 32 neuronas y función de activación ReLu y una capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 70 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.25: Arquitectura **VGG16-PFT-18 (MRI)**. Las 18 primeras capas congeladas cubren todos los bloques convolucionales. Solo se entrenan las capas Dense (256, 128 y 32 neuronas) sobre el conjunto de MRI.

Como última solución con el modelo de VGG16 en el conjunto de datos de MRI se ha utilizado también Parcial Fine Tunning pero en este caso se han congelado 16 capas, para poder adaptar el modelo mejor a los datos que se tienen, de esta manera podremos obtener un mejor resultado pero con mayor riesgo a overfitting.

Las capas densas que se han añadido en la cabecera final han sido una capa de Global Average Pooling, una capa densa con 256 neuronas y función de activación ReLu, una capa densa con 128 neuronas y función de activación ReLu, la tercera capa densa añadida tiene 32 neuronas y función de activación ReLu y una capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 25 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.26: Arquitectura **VGG16-PFT-16 (MRI)**. Las 16 primeras capas congeladas cubren los bloques 1-4 y una Conv del bloque 5. Las dos últimas capas convolucionales del bloque 5 se re-entrenan junto con las capas Dense (256, 128 y 32 neuronas) sobre el conjunto de MRI.

Igual que con el conjunto de datos de CT, el segundo modelo preentrenado que se ha utilizado ha sido ResNet50, en este caso se han propuesto 5 soluciones, la primera de ellas consiste en Fine Tuning, es decir, se re-entrena el modelo de nuevo para ajustar los pesos a los datos. Las capas densas que se han añadido en la cabecera final han sido una capa de Global Average Pooling, una capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, la tercera capa densa añadida tiene 32 neuronas y función de activación ReLu y una capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 15 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.27: Arquitectura **ResNet50-FT (MRI)**. Los bloques residuales de ResNet50 se re-entrenan completamente sobre el conjunto de MRI. Global Average Pooling reduce la salida a 2.048 valores, seguidos de tres capas Dense (128, 64 y 32 neuronas) y salida Sigmoid.

La segunda solución propuesta con este modelo ha sido siguiendo la técnica de Transfer Learning, congelando todas las capas y entrenando solamente las capas finales que se han añadido. En este caso se han añadido una capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, la tercera capa densa añadida tiene 32 neuronas y función de activación ReLu y una capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 90 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.28: Arquitectura **ResNet50-TL (MRI)**. Todos los bloques residuales permanecen congelados (en gris) con los pesos de ImageNet. Solo se entrenan las tres capas Dense (128, 64 y 32 neuronas) sobre el conjunto de MRI.

La tercera de las soluciones que se han implementado consiste en Transer Learning en dos pasos, es decir, se han entrenado en la primera fase las capas añadidas que consisten en una primera capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, otra capa densa con 32 neuronas y función de activación ReLu y una última capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. Una vez que la nueva cabecera de clasificación está entrenada en la primera fase, se procede a

una segunda fase que consiste en hacer Fine Tunning del modelo completo, es decir, entrenar las capas ya entrenadas en la fase previa con las convolucionales congeladas anteriormente, esto se hace con el objetivo de especializar el modelo. El modelo se ha entrenado con 80 épocas, un learning rate de 0.001 con el optimizador Adam, función de pérdida de Cross Entropy la primera vez y con 50 épocas, un learning rate de 0.00001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.29: Arquitectura **ResNet50-TL2 (MRI)**. Transfer Learning en dos pasos sobre el conjunto de MRI: primero se entrenan las capas densas con el modelo pre-entrenado congelado, y después se re-entrena la red completa con un learning rate reducido.

La cuarta prueba que se ha realizado ha sido haciendo Parcial Fine Tunning, en este caso se han congelado 143 capas del modelo original para poder conservar los pesos de esas capas iniciales y adaptar las demás capas convolucionales a los datos del problema. Las capas densas que se han añadido consisten en una primera capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, la tercera capa densa añadida tiene 32 neuronas y función de activación ReLu y una capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 50 épocas, un learning rate de 0.0001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.30: Arquitectura **ResNet50-PFT-143 (MRI)**. Las 143 primeras capas congeladas cubren hasta el primer bloque residual del bloque 5. Los dos últimos bloques residuales (en azul) se re-entrenan junto con las capas Dense (128, 64 y 32 neuronas) sobre el conjunto de MRI.

En la última solución propuesta para la clasificación y para este conjunto de datos con el modelo de ResNet50 se ha realizado haciendo Parcial Fine Tunning, en este caso se han congelado 80 capas del modelo original para poder conservar los pesos de esas capas iniciales y adaptar las demás capas convolucionales a los datos del problema. Las capas densas que se han añadido consisten en una primera capa densa con 128 neuronas y función de activación ReLu, una capa densa con 64 neuronas y función de activación ReLu, la tercera capa densa añadida tiene 32 neuronas y función de activación ReLu y una capa final con 1 neurona y función de activación Sigmoide para la clasificación binaria. El modelo se ha entrenado con 50 épocas, un learning rate de 0.0001 con el optimizador Adam, función de pérdida de Cross Entropy.




Figura 2.31: Arquitectura **ResNet50-PFT-80 (MRI)**. Las 80 primeras capas congeladas cubren hasta tres bloques residuales del bloque 3. El último bloque residual del bloque 3 (en azul), junto con los bloques 4 y 5 completos, se re-entrenan con las capas Dense (128, 64 y 32 neuronas) sobre el conjunto de MRI.

2.3.2. Arquitecturas para Segmentación

En esta segunda parte del trabajo el objetivo es en un único conjunto de datos que contiene imágenes de MRI (Resonancia Magnética) por lo que se han propuesto tres soluciones diferentes.

Se ha utilizado una arquitectura encoder-decoder, se ha utilizado la arquitectura U-Net [12], esto consiste en un modelo que se encarga en la primera parte de capturar el contexto y extraer las características de la imagen como texturas, formas o bordes, es decir, funciona exactamente igual que una red convolucional tradicional. Por otro lado, la segunda parte del modelo consiste en el proceso contrario a la primera parte, en lugar de ir reduciendo la dimensionalidad, lo que se hace es ampliar las dimensiones para ubicar.^{en} este caso el tumor en la imagen, es decir, genera la máscara de la imagen.

VGG16 En este caso en la primera parte de la arquitectura se ha utilizado la parte de los bloques convolucionales de la red VGG16, es decir, las capas que tiene son capas con filtros de 3x3, tiene 5 bloques convolucionales, en el primer bloque convolucional hay dos capas de Convolución2D con 64 filtros con filtros de 3x3, el segundo bloque tiene dos capas de Convolución2D con 128 filtros con filtros de 3x3 cada una de las capas, el tercer bloque tiene 3 capas de Convolución con 256 filtros cada una con filtros de 3x3, el cuarto bloque convolucional tiene también 3 capas convolucionales

de 512 filtros cada una con filtros de 3x3 y finalmente el último bloque convolucional tiene también 3 capas de Convolución2D con 512 filtros cada una y con filtros de 3x3. Después de cada bloque de convolución hay una capa de MaxPooling.

Para la segunda parte de este modelo y completar la arquitectura U-Net [12], se ha implementado un decoder simétrico al encoder con bloques de UpSampling2D que van aumentando progresivamente la resolución espacial. En cada bloque del decoder se concatenan las características del nivel correspondiente del encoder mediante skip connections, lo que permite recuperar los detalles perdidos durante la reducción de dimensionalidad. Cada bloque aplica capas de Convolución2D seguidas de Batch Normalization y activación ReLu. La red concluye con una capa convolucional de 1 solo filtro con función de activación Sigmoide para generar la máscara de predicción final a nivel de píxel.

Respecto al entrenamiento de este modelo, se ha utilizado la técnica de Fine Tuning completo, es decir, se ha re entrenado el modelo completo tanto para la primera parte que es el encoder como para la segunda que es el decoder. Se ha compilado con el optimizador Adam [11] con el learning rate por defecto que es 0.001, utilizando como función de pérdida la combinación de Binary Cross-Entropy y Jaccard Loss (Ecuación 1.6). El modelo se ha entrenado con un máximo de 160 épocas, aplicando Early Stopping con una paciencia de 13 épocas monitorizando la pérdida de validación.




Figura 2.32: Arquitectura **U-Net con encoder VGG16**. Los 5 bloques convolucionales de VGG16 actúan como encoder, reduciendo progresivamente la resolución espacial. El decoder implementa bloques de UpSampling2D con skip connections que concatenan las características del nivel correspondiente del encoder, recuperando los detalles espaciales. La capa final con 1 filtro y activación Sigmoide genera la máscara de predicción a nivel de píxel.

ResNet34 En este caso en la primera parte de la arquitectura se ha utilizado la parte de los bloques residuales de la red ResNet34 [6], es decir, a diferencia de VGG16 que utiliza bloques convolucionales simples, ResNet34 utiliza bloques residuales que incorporan conexiones de salto que suman la entrada del bloque a su salida, lo que permite entrenar redes más profundas sin problemas de desvanecimiento del gradiente. La red tiene una capa convolucional inicial con 64 filtros de 7x7 seguida de una capa de MaxPooling, y después 4 grandes bloques residuales: el primer bloque

contiene 3 bloques residuales con 64 filtros cada uno con filtros de 3x3, el segundo bloque contiene 4 bloques residuales con 128 filtros cada uno con filtros de 3x3, el tercer bloque contiene 6 bloques residuales con 256 filtros cada uno con filtros de 3x3 y finalmente el cuarto bloque contiene 3 bloques residuales con 512 filtros cada uno con filtros de 3x3. Entre cada bloque residual se reduce la dimensionalidad espacial a la mitad.

Para la segunda parte de este modelo y completar la arquitectura U-Net [12], se ha implementado un decoder simétrico al encoder con bloques de UpSampling2D que van aumentando progresivamente la resolución espacial. En cada bloque del decoder se concatenan las características del nivel correspondiente del encoder mediante skip connections, lo que permite recuperar los detalles perdidos durante la reducción de dimensionalidad. Cada bloque aplica capas de Convolución2D seguidas de Batch Normalization y activación ReLu. La red concluye con una capa convolucional de 1 solo filtro con función de activación Sigmoide para generar la máscara de predicción final a nivel de píxel.

Respecto al entrenamiento de este modelo, se ha utilizado la técnica de Fine Tuning completo, es decir, se ha re entrenado el modelo completo tanto para la primera parte que es el encoder como para la segunda que es el decoder. Se ha compilado con el optimizador Adam con un learning rate de 0.0001, utilizando como función de pérdida la combinación de Binary Cross-Entropy y Jaccard Loss (Ecuación 1.6). El modelo se ha entrenado con un máximo de 100 épocas, aplicando Early Stopping con una paciencia de 13 épocas monitorizando la pérdida de validación.




Figura 2.33: Arquitectura **U-Net con encoder ResNet34**. Los 4 bloques residuales de ResNet34 actúan como encoder, reduciendo progresivamente las dimensiones de las imágenes. El decoder implementa bloques de UpSampling2D con skip connections que concatenan las características del nivel correspondiente del encoder, recuperando los detalles espaciales. La capa final con 1 filtro y activación Sigmoide genera la máscara de predicción a nivel de píxel.

Capítulo 3

Resultados y Discusión

3.1. Resultados

En este capítulo se muestran y explican los resultados obtenidos de los modelos que se han propuesto para resolver el problema planteado en cada caso. Este análisis se ha hecho con el objetivo de encontrar el mejor resultado posible para la predicción y la segmentación de los tumores en las imágenes. En primer lugar se expondrán los resultados obtenidos de la parte de clasificación de las imágenes en tumor o sanas, diferenciando en los dos conjuntos de datos (CT y MRI), y en segundo lugar se expondrán los resultados de los modelos de segmentación de las imágenes de MRI. Los datos que se van a mostrar en esta sección corresponden a las curvas de entrenamiento que muestran el accuracy y la pérdida del modelo durante el entrenamiento, y la matriz de confusión, lo que va a permitir comparar objetivamente las distintas estrategias implementadas (modelos propios vs pre-entrenados).

3.1.1. Modelos de Clasificación

Conjunto de CT El primer modelo evaluado ([CNN-CT-Base](#)) corresponde a la arquitectura compuesta por dos capas convolucionales (con 8 y 16 filtros respectivamente) y una red neuronal densa final. A continuación, se muestran las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión.




Figura 3.1: Resultados del modelo [CNN-CT-Base](#) sobre el conjunto de CT. A pesar de alcanzar un 95.35 % de accuracy en test (439 VN, 442 VP, 21 FP, 22 FN), las curvas son buenas ya que se mantienen bastante parejas durante el entrenamiento y se estancan al final de las épocas.

Como se puede ver el modelo tiene un 95.35 % de accuracy en test, las curvas de entrenamiento son buenas ya que muestran que el accuracy y la pérdida ha ido igual en entrenamiento y en validación, en la curva de accuracy se puede ver como el entrenamiento se mantiene bastante igual en las dos curvas y en la de pérdida es donde mejora bastante durante las épocas hasta estancarse. Por otro lado, la matriz de confusión no es tan mala, como ya se ha comentado el modelo predice con 95.35 % de accuracy en test, los resultados muestran 439 verdaderos negativos, 21 falsos positivos, 22 falsos negativos y 442 verdaderos positivos (ver [Tabla 3.1](#)).

En el segundo de los modelos ([CNN-CT-Drop](#)) se ha añadido una capa de convolución con el objetivo de tener menos parámetros a entrenar y que la distribución de estos por capas sea mas homogénea, de esta manera se busca reducir el overfitting comprometiendo quizás los resultados del modelo. A continuación, se muestran las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión:




Figura 3.2: Resultados del modelo [CNN-CT-Drop](#) sobre el conjunto de CT. El entrenamiento es más estable que en el modelo base, con menor sobreajuste aunque el anterior tenía poco, este entrenamiento es mucho mejor. Mantiene un 95.78 % de accuracy (434 VN, 451 VP, 26 FP, 13 FN), logrando reducir el overfitting sin comprometer el rendimiento.

Se puede ver en las curvas de entrenamiento que el entrenamiento ha ido mejor que en el modelo anterior, es decir, no tiene tanto overfitting, aunque en las curvas

anteriores estaba bien igualmente. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado parecido al modelo pasado, los resultados muestran 434 verdaderos negativos, 26 falsos positivos, 13 falsos negativos y 451 verdaderos positivos, el accuracy del modelo también es del 95.78 % como el modelo anterior, así que lo que se ha conseguido en este modelo ha sido reducir bastante el overfitting sin comprometer el accuracy (ver [Tabla 3.1](#)).

En el tercero de los modelos ([CNN-CT-Deep](#)) se ha buscado subir el rendimiento a la hora de la predicción por lo que se han añadido capas y filtros en cada capa y para evitar el overfitting se ha añadido dropout. A continuación, se muestran las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión:




Figura 3.3: Resultados del modelo [CNN-CT-Deep](#) sobre el conjunto de CT. Las curvas no presentan sobreajuste, aunque el aprendizaje se estanca en las últimas épocas. Mejora respecto a los modelos anteriores con un 96 % de accuracy (455 VN, 436 VP, 5 FP, 28 FN), si bien los falsos negativos siguen siendo el punto más débil.

En este caso se puede ver que los resultados son bastante mejores que los de los modelos anteriores, las curvas de entrenamiento no tienen overfitting y se puede ver que el modelo no sigue aprendiendo al final, por lo que el aprendizaje se ha estancado. En cuanto a la matriz de confusión se observa que los resultados también son mejores que los de los modelos anteriores, mejoran todos los puntos pero el que menos mejora es el de falsos negativos que es el más importante ya que no se estaría tratando a alguien que lo necesita. Los resultados son 455 verdaderos negativos, 5 falsos positivos, 28 falsos negativos y 436 verdaderos positivos, el accuracy del modelo es del 96 % como el modelo anterior, así que lo que se ha conseguido en este modelo ha sido mejorar el accuracy (ver [Tabla 3.1](#)).

El cuarto modelo ([CNN-CT-DeepLR](#)) es igual que el tercero pero para que siga aprendiendo y no se estanque ese aprendizaje tiene un learning rate más pequeño y más épocas. A continuación, se muestran las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión:




Figura 3.4: Resultados del modelo [CNN-CT-DeepLR](#) sobre el conjunto de CT. La tasa de aprendizaje reducida y más épocas permiten superar el estancamiento del modelo anterior, alcanzando un 97 % de accuracy (455 VN, 444 VP, 5 FP, 20 FN) con curvas de entrenamiento estables.

Las curvas de entrenamiento también son muy buenas como en el modelo anterior, el objetivo era aumentar el rendimiento del modelo y se ha conseguido ya que se ha llegado a un 97 % de accuracy, los resultados en la matriz de confusión también han mejorado con 455 verdaderos negativos, 5 falsos positivos, 20 falsos negativos y 444 verdaderos positivos (ver [Tabla 3.1](#)).

En cuanto a los modelos pre-entrenados lo que se busca es mejorar el rendimiento y con las diferentes técnicas utilizadas se busca también obtener el mejor rendimiento posible. Los resultados del primer modelo ([VGG16-FT \(CT\)](#)) que es el de VGG16 de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.5: Resultados del modelo [VGG16-FT-CT](#) sobre el conjunto de CT. Las curvas no muestran sobreajuste, pero el rendimiento 96 % (455 VN, 432 VP, 5 FP, 32 FN) es inferior al último modelo propio, posiblemente porque el fine tuning completo no logra adaptar todos los pesos al dominio médico.

Se puede ver que las curvas de entrenamiento son buenas, es decir, no muestran overfitting por lo que el entrenamiento del modelo está bien. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado parecido al modelo pasado, los resultados muestran 455 verdaderos negativos, 5 falsos positivos, 32 falsos negativos y 432 verdaderos positivos, el accuracy del modelo es del 96 %, es peor que el último

modelo creado de cero y además los falsos positivos empeoran también, esto se puede deber a que el modelo pre-entrenado al haber cambiado todos los pesos del modelo no llegue a tanto rendimiento(ver [Tabla 3.1](#)).

El segundo de los modelos ([VGG16-TL \(CT\)](#)) pre-entrenados que sigue la técnica de Transfer Learning, por lo que los pesos del modelo no se han modificado durante el entrenamiento. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:






Figura 3.6: Resultados del modelo [VGG16-TL-CT](#) sobre el conjunto de CT. Las curvas se mantienen bastante parejas durante todo el entrenamiento, es decir no tiene sobre ajuste, obtiene un 95.24 % de accuracy (438 VN, 442 VP, 22 FP, 22 FN).

Se observa en los gráficos de las curvas que en este modelo no hay overfitting, por lo que el entrenamiento es bueno ya que las curvas se mantienen parejas y mejoran durante el entrenamiento hasta que se estancan al final. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado parecido al modelo pasado, los resultados muestran 438 verdaderos negativos, 22 falsos positivos, 22 falsos negativos y 442 verdaderos positivos, el accuracy del modelo es del 95.24 %, es un poco peor que el último modelo.(ver [Tabla 3.1](#)).

El tercero de los modelos pre-entrenados ([VGG16-PFT-17 \(CT\)](#)) sigue la técnica de Parcial Fine Tunning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:



(a) Curvas de entrenamiento.




(b) Matriz de confusión.


Figura 3.7: Resultados del modelo [VGG16-PFT17-CT](#) sobre el conjunto de CT. No hay sobreajuste ya que se mantienen las curvas parejas durante el entrenamiento hasta que se estancan. Alcanza un 97.29 % de accuracy (444 VN, 455 VP, 16 FP, 9 FN), el mejor resultado hasta el momento en CT.

Se observa en los gráficos de las curvas que en este modelo no hay overfitting, por lo que el entrenamiento es bueno ya que las curvas se mantienen bastante parejas durante todas las épocas, además se han entrenado más parámetros que en la prueba anterior o cual hace que el modelo se ajuste más a los datos por lo que el rendimiento es mejor. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 444 verdaderos negativos, 16 falsos positivos, 9 falsos negativos y 455 verdaderos positivos, el accuracy del modelo es del 97.29%, es mejor que el último modelo.(ver [Tabla 3.1](#)).

El cuarto de los modelos pre-entrenados ([VGG16-PFT-18 \(CT\)](#)) sigue la técnica de Parcial Fine Tuning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas, en este caso debido a que en el modelo anterior habia overfitting se ha decidido entrenar menos capas con el objetivo de reducir el overfitting. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y tambien la matriz de confusión son:



(a) Curvas de entrenamiento.



(b) Matriz de confusión.

Figura 3.8: Resultados del modelo [VGG16-PFT18-CT](#) sobre el conjunto de CT. El entrenamiento es bueno porque no hay diferencia relevante entre las curvas pero el rendimiento baja ligeramente a un 96 % de accuracy (444 VN, 443 VP, 16 FP, 21 FN) respecto al modelo anterior.

Se observa en los gráficos de las curvas que en este modelo no hay overfitting, por lo que el entrenamiento es bueno aunque el resultado es peor. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado ligeramente peor que el del modelo pasado, los resultados muestran 444 verdaderos negativos, 16 falsos positivos, 21 falsos negativos y 443 verdaderos positivos, el accuracy del modelo es del 96 %, es un poco peor que el último modelo(ver [Tabla 3.1](#)).

La última de las soluciones con el modelo de VGG16 para este conjunto de datos sigue la técnica de Parcial Fine Tunning ([VGG16-PFT-16 \(CT\)](#)), por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas, en este último caso aunque en el modelo anterior habia overfitting se ha decidido entrenar más capas con el objetivo de tener mejor rendimiento. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y tambien la matriz de confusión son:




Figura 3.9: Resultados del modelo [VGG16-PFT16-CT](#) sobre el conjunto de CT. No hay sobreajuste en este modelo ya que las curvas se mantienen parejas y no hay diferencia notable. Obtiene el mejor resultado de los preentrenados con un 97.51 % de accuracy (451 VN, 450 VP, 9 FP, 14 FN).

Se observa en los gráficos de las curvas que en este modelo no hay overfitting, por lo que el entrenamiento es bueno, el rendimiento es mejor que en los anteriores ya que se han entrenado más parámetros que en la prueba anterior lo cual hace que el modelo se ajuste más a los datos. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 451 verdaderos negativos, 9 falsos positivos, 14 falsos negativos y 450 verdaderos positivos, el accuracy del modelo es del 97.51 %, es mejor que el último modelo y de momento el mejor de los pre-entrenados(ver [Tabla 3.1](#)).

Para el segundo de los modelos pre-entrenados utilizados para este conjunto de datos que es el ResNet50 ([ResNet50-FT \(CT\)](#)), los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y tambien la matriz de confusión son:




Figura 3.10: Resultados del modelo [ResNet50-FT-CT](#) sobre el conjunto de CT. El fine tuning completo produce un sobreajuste severo: el modelo memoriza los datos de entrenamiento y apenas predice, con solo un 49 % de accuracy (285 VN, 168 VP, 175 FP, 296 FN).

Se observa en los gráficos de las curvas que el entrenamiento no es bueno porque hay mucho overfitting, el modelo se ha aprendido los datos de entrenamiento y no sabe predecir. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado malo también, los resultados muestran 285 verdaderos negativos, 175 falsos positivos, 296 falsos negativos y 168 verdaderos positivos, el accuracy del modelo es del 49 %, es bastante malo como mostraba ya la matriz de confusión y las curvas de entrenamiento (ver [Tabla 3.1](#)).

El segundo de los modelos de ResNet sigue la técnica de Transfer Learning ([ResNet50-TL \(CT\)](#)), por lo que los pesos del modelo no se han modificado durante el entrenamiento. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.11: Resultados del modelo [ResNet50-TL-CT](#) sobre el conjunto de CT. Mejora notablemente respecto al FT, no solo por el resultado sino también por las curvas en las que no hay sobreajuste. Alcanza un 88.74 % de accuracy (422 VN, 398 VP, 38 FP, 66 FN), limitado por entrenar solo la parte final.

Se observa en los gráficos de las curvas que el entrenamiento es bastante mejor que en la anterior solución esto se puede deber a que solo se ha entrenado la parte final, las curvas están mucho mejor que en el modelo anterior [ResNet50-FT-CT](#) ya que no

hay overfitting, se mantienen parejas hasta su estancamiento. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 422 verdaderos negativos, 38 falsos positivos, 66 falsos negativos y 398 verdaderos positivos, el accuracy del modelo es del 88.74 %, es mejor que el último modelo(ver [Tabla 3.1](#)).

El tercero de los modelos de ResNet50 ([ResNet50-TL2 \(CT\)](#)) sigue la técnica de Transfer Learning en dos pasos. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.12: Resultados del modelo [ResNet50-TL2-CT](#) sobre el conjunto de CT. Tras un inicio irregular, las curvas convergen y la diferencia entre entrenamiento y validación se reduce. Logra un 96.54 % de accuracy (445 VN, 447 VP, 15 FP, 17 FN), una gran mejora respecto al TL simple.

Se observa en los gráficos de las curvas que en este modelo al principio del entrenamiento el modelo se ajustaba muy poco a las predicciones en validación pero conforme avanzan las épocas se puede ver que el entrenamiento ha ido correctamente y la diferencia entre entrenamiento y validación es poca. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 445 verdaderos negativos, 15 falsos positivos, 17 falsos negativos y 447 verdaderos positivos, el accuracy del modelo es del 96.54 %(ver [Tabla 3.1](#)).

El cuarto de los modelos de ResNet sigue la técnica de Parcial Fine Tunning ([ResNet50-PFT-143 \(CT\)](#)), por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.13: Resultados del modelo [ResNet50-PFT143-CT](#) sobre el conjunto de CT. El entrenamiento no presenta sobreajuste general aunque muestra irregularidades en la validación. Obtiene un 94.37 % de accuracy (442 VN, 430 VP, 18 FP, 34 FN), inferior al modelo TL2 posiblemente por la irregularidad en el entrenamiento.

Se observa en los gráficos de las curvas que el entrenamiento a pesar de que en algunas épocas la diferencia en tre entrenamiento y validación es bastante grande, en general, no presenta overfitting, por lo que es un entrenamiento válido. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado un poco peor que el del modelo pasado, los resultados muestran 442 verdaderos negativos, 18 falsos positivos, 34 falsos negativos y 430 verdaderos positivos, el accuracy del modelo es del 94.37 %, es peor que el último modelo, esto se puede deber al cambio de técnica de entrenamiento que se ha utilizado o quizás por la irregularidad en el entrenamiento de este modelo en la predicción sobre el conjunto de validación(ver [Tabla 3.1](#)).

La última de las soluciones con el modelo de ResNet50 ([ResNet50-PFT-80 \(CT\)](#)) para este conjunto de datos sigue la técnica de Parcial Fine Tunning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas, en este último caso se ha decidido entrenar más capas con el objetivo de tener mejor rendimiento. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.14: Resultados del modelo [ResNet50-PFT80-CT](#) sobre el conjunto de CT. Las curvas están bien ajustadas salvo una irregularidad al final del entrenamiento. Alcanza un 97.08 % de accuracy (454 VN, 443 VP, 6 FP, 21 FN), el mejor resultado con ResNet50 en CT gracias a entrenar más parámetros.

Se observa en los gráficos de las curvas que las curvas de entrenamiento y validación están bastante ajustadas la una a la otra durante todas las épocas excepto al final donde hay una irregularidad tanto en el conjunto de entrenamiento como en el de validación en el que se ve mucho más acentuado. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 454 verdaderos negativos, 6 falsos positivos, 21 falsos negativos y 443 verdaderos positivos, el accuracy del modelo es del 97.08 %, es mejor que el último modelo a pesar de esa irregularidad durante el entrenamiento, esto se debe a que se han entrenado mas parámetros del modelo pre-entrenado y por lo tanto el modelo se ajusta más a los datos(ver [Tabla 3.1](#)).

Conjunto de MRI El primer modelo evaluado ([CNN-MRI-Base](#)) corresponde a la arquitectura compuesta por dos capas convolucionales (con 8 y 16 filtros respectivamente) y una red neuronal densa final. A continuación, se muestran las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión.




Figura 3.15: Resultados del modelo [CNN-MRI-Base](#) sobre el conjunto de MRI. Las curvas de accuracy son buenas al principio pero a pesar de la regularización al final de las épocas comienza a haber overfitting. Alcanza un 95.3 % de accuracy (391 VN, 562 VP, 9 FP, 38 FN).

Se observa en los gráficos de las curvas de aprendizaje que a pesar de haber overfitting al final aunque se haya regularizado el modelo las curvas no son malas. En cuanto a la matriz de confusión se puede ver que los resultados son 391 verdaderos negativos, 9 falsos positivos, 38 falsos negativos y 562 verdaderos positivos, el accuracy del modelo es del 95.3 %(ver [Tabla 3.2](#)).

En el segundo de los modelos ([CNN-MRI-Drop](#)) se han añadido capas de convolución con el objetivo de tener menos parámetros a entrenar y que la distribución de estos por capas sea mas homogénea, de esta manera se busca reducir el overfitting. A continuación, se muestran las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión:




Figura 3.16: Resultados del modelo [CNN-MRI-Drop](#) sobre el conjunto de MRI. Las curvas mejoran respecto al modelo base [CNN-MRI-BASE](#) ya que no hay nada de overfitting las curvas se mantienen parejas durante el entrenamiento hasta que se estancan. Muestra un rendimiento con un 96.8 % de accuracy (386 VN, 582 VP, 14 FP, 18 FN).

Se puede ver en las curvas de entrenamiento que el entrenamiento ha ido mejor que en el modelo anterior, es decir, las curvas son muy buenas ya que no presenta overfitting, están parejas hasta su estancamiento. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor al modelo pasado, los resultados muestran 386 verdaderos negativos, 14 falsos positivos, 18 falsos negativos y 582 verdaderos positivos, el accuracy del modelo es del 96.8 % mejor que el modelo anterior.(ver [Tabla 3.2](#)).

En el tercero de los modelos ([CNN-MRI-Deep](#)) se han añadido capas de convolución con el objetivo de tener más parámetros y mejorar el rendimiento del modelo, también para tener una mejor distribución de los parámetros. A continuación, se muestran las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión:




Figura 3.17: Resultados del modelo [CNN-MRI-Deep](#) sobre el conjunto de MRI. A pesar de los picos debidos al elevado número de épocas, la diferencia entre entrenamiento y validación es pequeña. Obtiene un 98.9 % de accuracy (394 VN, 595 VP, 6 FP, 5 FN), el mejor modelo propio para MRI.

Se puede ver en las curvas de aprendizaje que aunque hay bastantes picos debido al gran número de épocas que tiene el entrenamiento, sin embargo, el entrenamiento es

bastante bueno ya que la diferencia entre las curvas de entrenamiento y validación es poca y las dos mejoran con el número de épocas. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor al modelo anterior, los resultados muestran 394 verdaderos negativos, 6 falsos positivos, 5 falsos negativos y 595 verdaderos positivos, el accuracy del modelo es del 98.9% es bastante mejor que el modelo anterior(ver [Tabla 3.2](#)).

En cuanto a los modelos pre-entrenados lo que se busca es mejorar el rendimiento y con las diferentes técnicas utilizadas se busca también obtener el mejor rendimiento posible. Los resultados del primer modelo ([VGG16-FT \(MRI\)](#)) que es el de VGG16 de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.18: Resultados del modelo [VGG16-FT-MRI](#) sobre el conjunto de MRI. Las curvas son estables y sin sobreajuste hasta que se estanca al final. Obtiene un 99.9% de accuracy (400 VN, 599 VP, 0 FP, 1 FN).

Se puede ver que las curvas de aprendizaje son buenas, es decir, no muestran overfitting, las dos curvas están muy parejas hasta que se estanca el aprendizaje finalmente. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado muy bueno, los resultados muestran 400 verdaderos negativos, 0 falsos positivos, 1 falsos negativos y 599 verdaderos positivos, el accuracy del modelo es del 99.9% (ver [Tabla 3.2](#)).

El segundo de los modelos pre-entrenados ([VGG16-FT \(MRI, lr=0.0001\)](#)) sigue la misma técnica del primer modelo que es Fine Tuning pero en este caso se le han dado más épocas. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.19: Resultados del modelo **VGG16-FT-MRI** ($lr=0.0001$) sobre el conjunto de MRI. Con más épocas las curvas se estabilizan correctamente al final del entrenamiento. Alcanza un 99.5% de accuracy (397 VN, 598 VP, 3 FP, 2 FN), el mejor modelo de clasificación hasta el momento.

Se observa en los gráficos de las curvas que en este modelo el entrenamiento es mejor que el anterior ya que cuando acaba es cuando se empieza a aplanar tanto la curva de accuracy como la de pérdida. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mucho mejor al del modelo pasado, los resultados muestran 397 verdaderos negativos, 3 falsos positivos, 2 falsos negativos y 598 verdaderos positivos, el accuracy del modelo es del 99.5%, es mejor que el último modelo, de hecho es el mejor modelo de entrenamiento de momento (ver [Tabla 3.2](#)).

El tercero de los modelos pre-entrenados (**VGG16-TL (MRI)**) que sigue la técnica de Transfer Learning, por lo que los pesos del modelo no se han modificado durante el entrenamiento. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.20: Resultados del modelo **VGG16-TL-MRI** sobre el conjunto de MRI. El modelo aprende durante todas las épocas hasta su estancamiento al final, no hay overfitting ya que las curvas se mantienen parejas. Obtiene un 98% de accuracy (393 VN, 587 VP, 7 FP, 13 FN).

Se observa en los gráficos de las curvas que en este modelo no hay overfitting ya que las curvas se mantienen parejas hasta el final del entrenamiento. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado ligeramente peor al

modelo pasado **VGG16-FT-MRI** ($lr=0.0001$), los resultados muestran 393 verdaderos negativos, 7 falsos positivos, 13 falsos negativos y 587 verdaderos positivos, el accuracy del modelo es del 98 % (ver [Tabla 3.2](#)).

El cuarto de los modelos pre-entrenados (**VGG16-PFT-17 (MRI)**) sigue la técnica de Parcial Fine Tunning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.21: Resultados del modelo **VGG16-PFT17-MRI** sobre el conjunto de MRI. Entrenamiento correcto con poca diferencia entre curvas de entrenamiento y validación, estancándose al final. Alcanza un 99.2 % de accuracy (394 VN, 598 VP, 6 FP, 2 FN).

Se observa en los gráficos de las curvas de este modelo que el entrenamiento es correcto ya que las curvas no tienen mucha diferencia entre entrenamiento y validación y la mejora de las curvas se estanca al final de las épocas. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 394 verdaderos negativos, 6 falsos positivos, 2 falsos negativos y 598 verdaderos positivos, el accuracy del modelo es del 99.2 % (ver [Tabla 3.2](#)).

El quinto de los modelos pre-entrenados (**VGG16-PFT-18 (MRI)**) sigue la técnica de Parcial Fine Tunning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.22: Resultados del modelo [VGG16-PFT18-MRI](#) sobre el conjunto de MRI. Buen entrenamiento ya que no hay sobreajuste, las curvas se mantienen parejas durante el entrenamiento mejoran hasta su estancamiento final. Obtiene un 98.1 % de accuracy (394 VN, 587 VP, 6 FP, 13 FN).

Se observa en los gráficos de las curvas que el entrenamiento de este modelo es bueno, las curvas mejoran conforme aumenta el número de épocas y se acaba estancando, no hay overfitting ya que no hay diferencia notable entre las curvas, se mantienen parejas durante el entrenamiento. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado ligeramente peor al modelo pasado [VGG16-PFT17-MRI](#), los resultados muestran 394 verdaderos negativos, 6 falsos positivos, 13 falsos negativos y 587 verdaderos positivos, el accuracy del modelo es del 98.1 % (ver [Tabla 3.2](#)).

El sexto de los modelos pre-entrenados ([VGG16-PFT-16 \(MRI\)](#)) sigue la técnica de Parcial Fine Tunning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.23: Resultados del modelo [VGG16-PFT16-MRI](#) sobre el conjunto de MRI. Buen entrenamiento ya que no hay overfitting, las curvas no tienen diferencia significativa durante el entrenamiento. Mejora respecto al [VGG16-PFT18-MRI](#) con un 99.1 % de accuracy (398 VN, 593 VP, 2 FP, 7 FN).

Se observa en los gráficos de las curvas que el entrenamiento de este modelo es bueno, las curvas mejoran conforme aumenta el número de épocas y se acaba estancando

sin diferencia notable entre las curvas de entrenamiento y validación. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor al del modelo pasado ([VGG16-PFT18-MRI](#)), los resultados muestran 398 verdaderos negativos, 2 falsos positivos, 7 falsos negativos y 593 verdaderos positivos, el accuracy del modelo es del 99.1 % (ver [Tabla 3.2](#)).

Para el segundo de los modelos pre-entrenados utilizados para este conjunto de datos que es el ResNet50 [ResNet50-FT \(MRI\)](#), los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.24: Resultados del modelo [ResNet50-FT-MRI](#) sobre el conjunto de MRI. Sobreajuste severo: el modelo predice casi todo como sano, con solo un 41 % de accuracy (395 VN, 16 VP, 5 FP, 584 FN). El fine tuning completo de ResNet50 falla en ambos conjuntos de datos.

Se observa en los gráficos de las curvas que el entrenamiento no es bueno porque hay mucho overfitting, es decir, el modelo se ha aprendido los datos de entrenamiento y no sabe predecir. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado malo también ya que predice casi todo como sano, los resultados muestran 395 verdaderos negativos, 5 falsos positivos, 584 falsos negativos y 16 verdaderos positivos, el accuracy del modelo es del 41 %, es bastante malo como mostraba ya la matriz de confusión y las curvas de entrenamiento (ver [Tabla 3.2](#)).

El segundo de los modelos de ResNet ([ResNet50-TL \(MRI\)](#)) sigue la técnica de Transfer Learning, por lo que los pesos del modelo no se han modificado durante el entrenamiento. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.25: Resultados del modelo [ResNet50-TL-MRI](#) sobre el conjunto de MRI. Curvas irregulares con muchos picos por el alto número de épocas, pero con poca diferencia entre entrenamiento y validación y mejora progresiva. Alcanza un 92.7 % de accuracy (374 VN, 553 VP, 26 FP, 47 FN).

Se observa en los gráficos de las curvas que el entrenamiento es bastante mejor que en la anterior solución a pesar de que la curva es bastante irregular en cuanto a que tiene muchos picos, esto se debe a que tiene bastantes épocas, pero obviando esto las curvas son buenas ya que hay poca diferencia entre entrenamiento y validación y además conforme avanzan las épocas el rendimiento del modelo mejora hasta que se estanca. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 374 verdaderos negativos, 26 falsos positivos, 47 falsos negativos y 553 verdaderos positivos, el accuracy del modelo es del 92.7 % lo cual es bastante mejor que el modelo anterior (ver [Tabla 3.2](#)).

El tercero de los modelos de ResNet50 ([ResNet50-TL2 \(MRI\)](#)) sigue la técnica de Transfer Learning en dos pasos. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.26: Resultados del modelo [ResNet50-TL2-MRI](#) sobre el conjunto de MRI. Tras un inicio irregular, las curvas convergen con diferencia mínima entre entrenamiento y validación. Gran mejora con un 99.2 % de accuracy (395 VN, 597 VP, 5 FP, 3 FN).

Se observa en los gráficos de las curvas que en este modelo al principio del entrenamiento el modelo se ajustaba muy poco a las predicciones en validación pero

conforme avanzan las épocas se puede ver que el entrenamiento ha ido correctamente y la diferencia entre entrenamiento y validación es muy poca, lo que quiere decir que el modelo predice muy bien las imágenes de validación. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mucho mejor que el del modelo pasado, los resultados muestran 395 verdaderos negativos, 5 falsos positivos, 3 falsos negativos y 597 verdaderos positivos, el accuracy del modelo es del 99.2 % (ver [Tabla 3.2](#)).

El cuarto de los modelos de ResNet ([ResNet50-PFT-143 \(MRI\)](#)) sigue la técnica de Parcial Fine Tunning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas. Los resultados del segundo modelo de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:




Figura 3.27: Resultados del modelo [ResNet50-PFT143-MRI](#) sobre el conjunto de MRI. Sin sobreajuste las curvas no tienen diferencia muy significativa, mejoran hasta el estancamiento. Obtiene un 97.5 % de accuracy (396 VN, 579 VP, 4 FP, 21 FN), inferior al TL2.

Se observa en los gráficos de las curvas que el entrenamiento no presenta overfitting, por lo que es un entrenamiento bueno, las curvas se mantienen parejas hasta el estancamiento. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado un poco peor que el del modelo pasado, los resultados muestran 396 verdaderos negativos, 4 falsos positivos, 21 falsos negativos y 579 verdaderos positivos, el accuracy del modelo es del 97.5 %, es peor que el último modelo ([ResNet50-TL2-MRI](#)), esto se puede deber al cambio de técnica de entrenamiento que se ha utilizado (ver [Tabla 3.2](#)).

La última de las soluciones con el modelo de ResNet50 ([ResNet50-PFT-80 \(MRI\)](#)) para este conjunto de datos sigue la técnica de Parcial Fine Tunning, por lo que los pesos del modelo solo se han modificado durante el entrenamiento en ciertas capas, en este último caso se ha decidido entrenar más capas con el objetivo de tener mejor rendimiento. Los resultados de las curvas de entrenamiento a lo largo de las épocas, evaluando tanto la precisión (Accuracy) como la pérdida (Binary Crossentropy) y también la matriz de confusión son:





Figura 3.28: Resultados del modelo [ResNet50-PFT80-MRI](#) sobre el conjunto de MRI. Al principio las curvas divergen, pero a mitad del entrenamiento convergen con diferencia mínima. Alcanza un 99.2% de accuracy (396 VN, 596 VP, 4 FP, 4 FN), mejor que el [ResNet50-PFT143-MRI](#) al entrenar más parámetros.

Se observa en los gráficos de las curvas que las curvas de entrenamiento y validación al principio tienen mucha diferencia entre las dos, es decir, que en la curva de validación el modelo no se comporta bien pero a mitad del entrenamiento el rendimiento mejora mucho ya que la diferencia entre las dos curvas es mínima. En cuanto a la matriz de confusión se puede ver que se obtiene un resultado mejor que el del modelo pasado, los resultados muestran 396 verdaderos negativos, 4 falsos positivos, 4 falsos negativos y 596 verdaderos positivos, el accuracy del modelo es del 99.2%, es mejor que el último modelo a pesar de esa irregularidad durante el entrenamiento(ver [Tabla 3.2](#)).

3.1.2. Modelos de Segmentación

El primer modelo de segmentación entrenado es la arquitectura [U-Net-VGG16](#) se ha aplicado Fine Tuning completo sobre el modelo que se usa como encoder que es el VGG16. Se utiliza el optimizador Adam con una tasa de aprendizaje de 0.001, la función de pérdida combinada Binary Cross-Entropy + Jaccard Loss (Ecuación 1.6), un máximo de 160 épocas y Early Stopping con paciencia de 13 épocas. Los resultados obtenidos por este modelo son (ver [Tabla 3.3](#)).



(a) Curvas de entrenamiento.




(b) Ejemplo de predicción: imagen de entrada, máscara real y predicción del modelo.

Figura 3.29: Resultados del modelo [U-Net-VGG16](#). Alcanza un IoU (Ecuación 1.3) de 0.7995 y un Dice Score (Ecuación 1.4) de 0.8886. La precisión (0.9009) supera al recall (0.8765) lo que indica que cuando el modelo predice una zona como tumor está bastante seguro de que es tumor.

Se observa en las curvas de entrenamiento que tanto en la curva de IoU como en la de pérdida el modelo mejora con las épocas hasta que se estanca a pesar de tener algunos picos al principio, en cuanto al sobre ajuste se puede ver que no tiene ya que las curvas se mantienen bastante parejas sin una diferencia grande durante el entrenamiento hasta su estancamiento. Las métricas de segmentación muestran que el modelo obtiene un IoU (Ecuación 1.3) de 0.7995 y un Dice Score (Ecuación 1.4) de 0.8886, lo que indica una buena superposición entre la máscara predicha y la máscara real de la imagen. La precisión alcanza 0.9009 mientras que el recall se queda en 0.8765, lo que indica que cuando el modelo predice una zona como tumor está bastante seguro de que es tumor aunque no esté prediciendo el tumor completo (13 % sin predecir).

El segundo modelo de segmentación entrenado es la arquitectura [U-Net-ResNet34](#) se ha aplicado Fine Tuning completo sobre el modelo que se usa como enconder que es el ResNet34. Se utiliza el optimizador Adam con una tasa de aprendizaje de 0.0001, la función de pérdida combinada Binary Cross-Entropy + Jaccard Loss (Ecuación 1.6), un máximo de 100 épocas y Early Stopping con paciencia de 13 épocas. Los resultados obtenidos por este modelo son (ver [Tabla 3.3](#)).



(a) Curvas de entrenamiento.



(b) Ejemplo de predicción: imagen de entrada, máscara real y predicción del modelo.

Figura 3.30: Resultados del modelo [U-Net-ResNet34](#). Mejora respecto al VGG16 [U-Net-VGG16](#) con un IoU (Ecuación 1.3) de 0.8240 y un Dice Score (Ecuación 1.4) de 0.9035. El equilibrio entre precisión (0.9087) y recall (0.8983) es notablemente superior, predice más region tumoral con prácticamente la misma fiabilidad.

Se observa en las curvas de entrenamiento que tanto en la curva de IoU como en la de pérdida el modelo converge rápido y de manera estable sin picos grandes, en cuanto al sobre ajuste se puede ver que no tiene ya que las curvas se mantienen bastante parejas sin una diferencia grande durante el entrenamiento hasta su estancamiento. Las métricas de segmentación muestran que el modelo obtiene un IoU (Ecuación 1.3) de 0.8240 y un Dice Score (Ecuación 1.4) de 0.9035, lo que indica una buena superposición entre la máscara predicha y la máscara real de la imagen. La precisión alcanza 0.9087 mientras que el recall se queda en 0.8983, lo que indica que cuando el modelo predice una zona como tumor está bastante seguro de que es tumor aunque no esté prediciendo el tumor completo (10 % sin predecir).

Cuadro 3.1: Comparativa de todos los modelos de clasificación evaluados sobre el conjunto de CT. Se muestra la técnica de entrenamiento, el accuracy (Ecuación 1.1) en test, los valores de la matriz de confusión y la presencia de sobreajuste.

Modelo	Técnica	Accuracy (%)	VN	VP	FP	FN	Overfitting
CNN-CT-Base	CNN propia	95.35	439	442	21	22	No
CNN-CT-Drop	CNN propia	95.78	434	451	26	13	No
CNN-CT-Deep	CNN propia	96.00	455	436	5	28	No
CNN-CT-DeepLR	CNN propia	97.00	455	444	5	20	No
VGG16-FT-CT	Fine Tuning	96.00	455	432	5	32	No
VGG16-TL-CT	Transfer L.	95.24	438	442	22	22	No
VGG16-PFT17-CT	Parcial FT	97.29	444	455	16	9	No
VGG16-PFT18-CT	Parcial FT	96.00	444	443	16	21	No
VGG16-PFT16-CT	Parcial FT	97.51	451	450	9	14	No
ResNet50-FT-CT	Fine Tuning	49.00	285	168	175	296	Sí
ResNet50-TL-CT	Transfer L.	88.74	422	398	38	66	No
ResNet50-TL2-CT	Transfer L. 2p	96.54	445	447	15	17	No
ResNet50-PFT143-CT	Parcial FT	94.37	442	430	18	34	No
ResNet50-PFT80-CT	Parcial FT	97.08	454	443	6	21	No

Cuadro 3.2: Comparativa de todos los modelos de clasificación evaluados sobre el conjunto de MRI. Se muestra la técnica de entrenamiento, el accuracy (Ecuación 1.1) en test, los valores de la matriz de confusión y la presencia de sobreajuste.

Modelo	Técnica	Accuracy (%)	VN	VP	FP	FN	Overfitting
CNN-MRI-Base	CNN propia	95.30	391	562	9	38	Leve
CNN-MRI-Drop	CNN propia	96.80	386	582	14	18	No
CNN-MRI-Deep	CNN propia	98.90	394	595	6	5	No
VGG16-FT-MRI	Fine Tuning	99.90	400	599	0	1	No
VGG16-FT-MRI (lr=0.0001)	Fine Tuning	99.50	397	598	3	2	No
VGG16-TL-MRI	Transfer L.	98.00	393	587	7	13	No
VGG16-PFT17-MRI	Parcial FT	99.20	394	598	6	2	No
VGG16-PFT18-MRI	Parcial FT	98.10	394	587	6	13	No
VGG16-PFT16-MRI	Parcial FT	99.10	398	593	2	7	No
ResNet50-FT-MRI	Fine Tuning	41.00	395	16	5	584	Sí
ResNet50-TL-MRI	Transfer L.	92.70	374	553	26	47	No
ResNet50-TL2-MRI	Transfer L. 2p	99.20	395	597	5	3	No
ResNet50-PFT143-MRI	Parcial FT	97.50	396	579	4	21	No
ResNet50-PFT80-MRI	Parcial FT	99.20	396	596	4	4	No

Cuadro 3.3: Comparativa de los modelos de segmentación evaluados sobre el conjunto de test. Se reportan las métricas IoU (Ecuación 1.3), Dice Score (Ecuación 1.4), Accuracy (Ecuación 1.1), Precision, Recall y F1-Score.

Modelo	IoU	Dice	Accuracy	Precision	Recall	F1-Score
U-Net-VGG16	0.7995	0.8886	0.9938	0.9009	0.8765	0.8886
U-Net-ResNet34	0.8240	0.9035	0.9945	0.9087	0.8983	0.9035

Capítulo 4

Conclusiones y proyección futura.

4.1. Conclusiones

En este último capítulo se exponen las conclusiones finales del desarrollo y evaluación de los modelos desarrollados en este trabajo. El objetivo fundamental de este proyecto ha sido investigar e implementar soluciones basadas en técnicas de Deep Learning para mejorar la precisión en la detección de tumores cerebrales a través de imágenes médicas (Resonancias Magnéticas y Tomografías Computarizadas). A lo largo de los capítulos anteriores se ha detallado el ciclo de vida completo de los modelos desarrollados: desde el análisis y preprocesamiento de los conjuntos de datos, hasta el diseño, entrenamiento y validación de diversas arquitecturas de Redes Neuronales Convolucionales (tanto modelos propios como arquitecturas pre-entrenadas).

Las conclusiones se han desarrollado en base a las dos grandes fases del proyecto: en primer lugar, los resultados obtenidos en la tarea de clasificación (detección de la presencia o no de tumor); y en segundo lugar, el desempeño de los modelos en la tarea de segmentación (delimitación exacta del área tumoral). Finalmente, se presentará una valoración global del impacto de estas herramientas en el ámbito médico y se propondrán futuras líneas de investigación.

4.1.1. Conclusiones para Clasificación

En el conjunto de CT (ver [Tabla 3.1](#)), el mejor resultado se ha obtenido con el modelo [VGG16-PFT16-CT](#) aplicando Partial Fine Tunning con 16 capas congeladas, que ha alcanzado un accuracy del 97.51 % con 9 falsos positivos y 14 falsos negativos. Los modelos propios, a pesar de tener arquitecturas mucho más simples, han demostrado ser competitivos: el cuarto modelo propio ([CNN-CT-DeepLR](#)) ha alcanzado un 97 % de accuracy, lo que sugiere que para este dataset la complejidad de la arquitectura no es el factor determinante y que un buen ajuste de los parámetros a la hora de entrenar puede compensar la falta de profundidad, por lo que si se tiene menos capacidad de computación se puede tener un buen modelo sin comprometer demasiado el resultado. Por su parte ResNet50 con Fine Tunning completo ([ResNet50-FT-CT](#)) ha obtenido un resultado muy malo (49 % accuracy), lo que evidencia que entrenar desde cero todos los pesos de una red tan profunda con un dataset de este tamaño provoca overfitting severo. Sin embargo, la mejor configuración de ResNet50 con Partial Fine Tunning ([ResNet50-PFT80-CT](#)) ha llegado al 97.08 %, confirmando que la clave con redes profundas está en congelar suficientes capas

para aprovechar las características ya aprendidas del modelo de manera previa.

En el conjunto de MRI (ver [Tabla 3.2](#)) los resultados han sido en general mejores, probablemente porque las resonancias magnéticas ofrecen mayor contraste y detalle para diferenciar tejido sano de tumoral. El mejor modelo global ha sido [VGG16-FT-MRI](#) con Fine Tuning el cual ha alcanzado un 99.9 % de accuracy con 0 falsos positivos y tan solo 1 falso negativo, lo cual es un resultado muy destacable para un problema de clasificación binaria médica, ya que implica que el modelo clasifica correctamente prácticamente todas las imágenes del conjunto de test. Los modelos propios también han mejorado significativamente respecto a CT, con el tercer modelo propio ([CNN-MRI-Deep](#)) alcanzando un 98.9 %, lo que refuerza la idea de que el dataset de MRI es más fácil de clasificar y que si se necesita un modelo con menos necesidad de computación se puede escoger el modelo creado desde cero sin comprometer el resultado demasiado. ResNet50 ha mostrado un patrón similar al de CT: el Fine Tuning (CNN-MRI-DeepLR) completo ha fallado (41 % accuracy), pero las configuraciones con Transfer Learning en dos pasos ([ResNet50-TL2-MRI](#)) y con Partial Fine Tuning ([ResNet50-PFT80-MRI](#)) han obtenido resultados muy buenos, alcanzando ambas un 99.2 % de accuracy.

Se pueden destacar dos cosas, la primera de ellas es que el Transfer Learning, Partial Fine Tuning o Fine Tuning con learning rates bajos ha sido consistentemente la estrategia más eficaz, frente a entrenar redes pre-entrenadas completamente desde cero, que en el caso de ResNet50 con Fine Tuning completo ha provocado un overfitting severo en ambos conjuntos de datos (49 % en CT y 41 % en MRI). Y la segunda de ellas es que VGG16 ha superado a ResNet50 en casi todas las configuraciones equivalentes, lo cual puede deberse a que la menor profundidad de VGG16 se adapta mejor al tamaño de los datasets utilizados

En base a estos resultados, el modelo que se debería de elegir como el mejor es el [VGG16-FT-MRI](#) sobre el conjunto de MRI, al ser el que mejor equilibrio ha mostrado entre accuracy y estabilidad en el entrenamiento, con un resultado casi perfecto de 99.9 % y tan solo 1 falso negativo en todo el conjunto de test. Finalmente, se puede decir que el objetivo de este apartado se ha cumplido ya que se proporciona una herramienta que reduce el error humano en el diagnóstico temprano, garantizando que prácticamente ninguna imagen con presencia de tumor pase desapercibida antes de la fase de segmentación.

4.1.2. Conclusiones para Segmentación

En la tarea de segmentación (ver [Tabla 3.3](#)) se han evaluado dos arquitecturas basadas en U-Net con encoders pre-entrenados, ambas entrenadas mediante Fine Tuning completo con la función de pérdida combinada BCE + Jaccard Loss (Ecuación 1.6). A diferencia de la clasificación, donde el accuracy es la métrica principal, en segmentación las métricas más relevantes son el IoU (Ecuación 1.3) y el Dice Score (Ecuación 1.4).

El modelo [U-Net-VGG16](#) ha obtenido un IoU de 0.7995 y un Dice Score de 0.8886, lo que indica una buena superposición entre la máscara predicha y la real. La precisión (0.9009) supera al recall (0.8765), lo que significa que cuando el modelo predice una zona como tumor está bastante seguro de que lo es, aunque deja aproximadamente un 13 % del área tumoral sin predecir. El modelo [U-Net-ResNet34](#) ha mejorado en todas las métricas, alcanzando un IoU de 0.8240 y un Dice Score de 0.9035. El equilibrio entre precisión (0.9087) y recall (0.8983) es notablemente superior al del VGG16, lo que indica que este modelo no solo mantiene una alta fiabilidad en sus predicciones sino que además detecta

una mayor proporción del área tumoral real, reduciendo el porcentaje sin predecir al 10 %.

Finalmente el modelo [U-Net-ResNet34](#) es el más adecuado para la tarea de segmentación, ya que ofrece la mejor delimitación del tumor con un buen equilibrio entre precisión y recall. Al igual que en clasificación, se confirma que la combinación de arquitecturas pre-entrenadas con Fine Tuning controlado es la estrategia más eficaz, y que no es necesario recurrir a arquitecturas más complejas para obtener resultados competitivos en segmentación de tumores cerebrales.

4.2. Trabajo futuro

Apéndice A

Anexos

A.1. Ejemplos del lenguaje de marcado Latex

This document is an example of BibTeX using in bibliography management. Three items are cited: *The L^AT_EX Companion* book [?], the Einstein journal paper [?], and the Donald Knuth's website [?]. The L^AT_EX related items are [?, ?]¹.

Texto en el párrafo 1.

Texto en el párrafo 2.

Texto en el párrafo 3.

- Consideración 1
- Consideración 2

1. Punto 1

2. Punto 2

A continuación se muestra una ecuación:

$$\int_0^1 \frac{1}{x^2 + 1} dx$$

Podemos incluir imágenes en formato: png, pdf o jpg.

En la figura A.1 se muestra un diagrama realizado con <https://www.yworks.com/products/yed>:

Imagen 1





Imagen 2



¹Esto está tomado de https://www.overleaf.com/learn/latex/Bibliography_management_with_bibtex




Figura A.1: Esta es una figura que latex decide donde colocar (floating) en el documento.

Este es un ejemplo de una tabla:

Columna 1	Columna 2
1	2

O la misma tabla centrada:

Columna 1	Columna 2
1	2

Para generar el fichero PDF:

```
pdflatex ejemplo-memoria.tex
bibtex ejemplo-memoria
pdflatex ejemplo-memoria.tex
```

También se puede usar `latexmk` que automáticamente regenera la bibliografía.

```
latexmk -pdf ejemplo-memoria.tex
```

Bibliografía

- [1] Asociación Española Contra el Cáncer. Cáncer de cerebro o sistema nervioso central. <https://www.contraelcancer.es/es/todo-sobre-cancer/tipos-cancer/sistema-nervioso-central>, 2024.
- [2] Sociedad Española de Neurología. 8 de junio de 2023: Día internacional de los tumores cerebrales. <https://www.sen.es/saladeprensa/pdf/Link406.pdf>, 2023.
- [3] Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, Arnaud Arindra Adiyoso Setio, Francesco Ciompi, Mohsen Ghafoorian, Jeroen A.W.M. van der Laak, Bram van Ginneken, and Clara I. Sánchez. A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42:60–88, 2017.
- [4] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [5] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*, 2014.
- [6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.
- [7] Amaresha Stable and Raymond J. Young. Current clinical brain tumor imaging. *Neurosurgery*, 81(3):397–415, 2017.
- [8] Murtoza Likhon. Brain Tumor Multimodal Image Dataset (CT and MRI). [Kaggle Dataset](#), 2024.
- [9] Mateusz Buda. LGG MRI Segmentation Dataset. [Kaggle Dataset](#), 2019.
- [10] Mateusz Buda, Ashirbani Saha, and Maciej A Mazurowski. Association of genomic subtypes of lower-grade gliomas with shape features automatically extracted by a deep learning algorithm. *Computers in Biology and Medicine*, 109:218–225, 2019.
- [11] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2015.
- [12] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pages 234–241, 2015.